

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



Lê Văn Thắng

NGHIÊN CỨU, XÂY DỰNG HỆ THỐNG TÓM TẮT
TIN TỨC TIẾNG VIỆT SỬ DỤNG
MÔ HÌNH NGÔN NGỮ LỚN

BÁO CÁO BÀI TẬP LỚN MÔN XỬ LÝ NGÔN NGỮ TỰ
NHIÊN

Ngành: Khoa học Máy tính

Người hướng dẫn: TS. Vương Thị Hồng

HÀ NỘI – 2026

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY



Le Van Thang

**RESEARCH AND DEVELOPMENT OF A
VIETNAMESE NEWS SUMMARIZATION SYSTEM
USING LARGE LANGUAGE MODELS**

NLP COURSE FINAL PROJECT REPORT

Major: Computer Science

Supervisor: Dr. Vuong Thi Hong

HA NOI – 2026

TÓM TẮT KHÓA LUẬN

Sự bùng nổ của thông tin trực tuyến tại Việt Nam đã đặt ra nhu cầu cấp thiết về việc tóm tắt nhanh nội dung bài báo. Các hệ thống tóm tắt dựa trên một Mô hình ngôn ngữ lớn (LLM) đơn lẻ hiện nay vẫn cho ra kết quả không ổn định, trong khi kỹ thuật Mixture-of-Agents (MoA) — kết hợp nhiều LLM thông qua kiến trúc đa tác nhân bao gồm các tác nhân đề xuất và tổng hợp — chưa từng được nghiên cứu cho bài toán tóm tắt tin tức tiếng Việt. Bên cạnh đó, các hệ số đo lường phổ biến như ROUGE hay BERTScore chủ yếu đo độ trùng lặp với bài gốc, vốn kém hiệu quả trong việc phản ánh chất lượng khi mô hình được phép diễn giải lại và rút gọn ý tưởng.

Khóa luận này thực hiện ba đóng góp. Thứ nhất, giới thiệu hệ thống Fiber — một tiện ích mở rộng trình duyệt có khả năng tóm tắt tin tức tiếng Việt theo thời gian thực, hỗ trợ các LLM đa nền tảng (OpenAI, Anthropic, Google). Thứ hai, áp dụng pipeline MoA cho bài toán tóm tắt tiếng Việt có neo ngữ cảnh gốc, bằng cách đưa trực tiếp bài viết nguồn vào tác nhân tổng hợp như một kết nối phần dư nhằm đảm bảo tính trung thực. Thứ ba, đề xuất khung đánh giá đa trục: Trục A (giữ lại nội dung: ROUGE, BERTScore), Trục B (chất lượng: đánh giá rubric và xếp hạng bởi LLM-Judge), và Trục C (đánh giá mù bởi con người), qua đó chỉ ra hạn chế của các hệ số overlap truyền thống.

Trên tập dữ liệu 154 bài báo, pipeline MoA cho kết quả tóm tắt vượt trội so với các mô hình đơn lẻ (68,9% tỷ lệ thắng). Các đánh giá định lượng và khảo sát độc lập trên 17 tình nguyện viên đều đồng thuận với kết quả này, đồng thời phản ánh rõ tác động của yếu tố chủ đề lên sở thích tiếp nhận thông tin của độc giả.

Từ khoá: Tóm tắt tin tức tiếng Việt, mô hình ngôn ngữ lớn, Mixture-of-Agents, tiện ích mở rộng trình duyệt, khung đánh giá đa trục.

LỜI CAM ĐOAN

Tôi xin cam đoan đây là công trình nghiên cứu khoa học độc lập của riêng tôi, được thực hiện dưới sự hướng dẫn khoa học của TS. Vương Thị Hồng.

Đề tài khóa luận tốt nghiệp: *“Nghiên cứu, xây dựng hệ thống tóm tắt tin tức tiếng Việt sử dụng mô hình ngôn ngữ lớn”* là kết quả của quá trình nghiên cứu nghiêm túc và nỗ lực thực sự của bản thân tôi. Các số liệu thực nghiệm, kết quả nghiên cứu được trình bày trong khóa luận này hoàn toàn trung thực, khách quan và chưa từng được công bố tại bất kỳ công trình khoa học nào khác.

Tôi xin hoàn toàn chịu trách nhiệm về nội dung, tính chính xác và sự trung thực của khóa luận này.

Hà Nội, tháng 6 năm 2026

Sinh viên



Lê Văn Thắng

LỜI CẢM ƠN

Trước tiên, tôi xin bày tỏ lòng biết ơn sâu sắc nhất đến giáo viên hướng dẫn của tôi, TS. Vương Thị Hồng, người đã định hướng, kiên nhẫn đồng hành và góp ý chỉnh sửa chi tiết cho từng chương của khóa luận này. Sự tận tâm và những góp ý của cô đã khiến khoảng thời gian nghiên cứu và phát triển khóa luận này trở nên vô cùng ý nghĩa với tôi.

Tôi xin chân thành cảm ơn các thầy cô giảng viên và cán bộ Khoa Công nghệ thông tin, Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội, đã trang bị cho tôi nền tảng kiến thức vững chắc và tư duy cần thiết qua bốn năm đại học. Đó là hành trang không thể thiếu để tôi hoàn thành dự án này.

Cuối cùng, tôi xin gửi lời cảm ơn chân thành đến các bạn bè và đồng nghiệp đã tham gia vào thí nghiệm đánh giá của con người (Axis C) của công trình; sự kiên nhẫn và trung thực của các bạn trong việc xếp hạng các bản tóm tắt cố tình được thiết kế để khó phân biệt đã mang lại giá trị khoa học to lớn cũng như những phát hiện thú vị.

Hà Nội, tháng 6 năm 2026

Lê Văn Thắng

MỤC LỤC

TÓM TẮT KHÓA LUẬN	i
LỜI CAM ĐOAN	ii
LỜI CẢM ƠN	iii
MỤC LỤC	iv
DANH MỤC HÌNH VẼ	vi
DANH MỤC BẢNG BIỂU	vii
DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT	viii
MỞ ĐẦU	1
Chương 1: Giới thiệu bài toán	4
1.1 Bài toán tóm tắt văn bản tự động	4
1.2 Pipeline Mixture-of-Agents (MoA)	5
1.3 Các công trình liên quan và khoảng trống nghiên cứu	5
1.4 Tổng kết chương	6
Chương 2: Cơ sở lý thuyết	7
2.1 Các mô hình ngôn ngữ lớn	7
2.1.1 Kiến trúc Transformer	7
2.1.2 Các mô hình được sử dụng	7
2.2 Cơ sở đánh giá chất lượng tóm tắt	8
2.2.1 Độ phủ nội dung (Trục A)	8
2.2.2 Phương pháp luận LLM-Judge (Trục B)	9
2.2.3 Đánh giá bởi con người (Trục C)	10
2.3 Tổng kết chương	11
Chương 3: Thiết kế và xây dựng hệ thống	12
3.1 Phân tích yêu cầu hệ thống	12
3.1.1 Yêu cầu chức năng	12
3.1.2 Yêu cầu phi chức năng	12
3.2 Kiến trúc tổng quan hệ thống	13
3.3 Module tóm tắt văn bản	13
3.3.1 Quy trình tóm tắt văn bản	13
3.4 Pipeline dung hợp đa tác nhân (MoA)	16
3.4.1 Thiết kế hệ thống hai lớp	16
3.4.2 Lớp đề xuất	16

3.4.3	Lớp tổng hợp	17
3.4.4	Kết nối phần dư bài viết gốc	17
3.4.5	Thực nghiệm kỹ thuật câu lệnh đối với mô hình tổng hợp	17
3.5	Khung đánh giá ba trục	18
3.5.1	Trục A — Khả năng giữ lại nội dung	18
3.5.2	Trục B — Chất lượng và Mức độ ưu tiên	19
3.5.3	Trục C — Đánh giá bởi con người	21
3.5.4	Phân tích thống kê	22
3.6	Tổng kết chương	23
Chương 4:	Thực nghiệm và đánh giá	24
4.1	Thiết lập thực nghiệm	24
4.1.1	Tập dữ liệu	24
4.1.2	Các mô hình so sánh	24
4.1.3	Các hệ đo lường	25
4.2	Kết quả Trục A — Khả năng giữ lại nội dung	25
4.3	Kết quả Trục B — Chất lượng và sự ưu tiên	26
4.3.1	Đánh giá theo Rubric (FLASK cải tiến, 1–5)	26
4.3.2	Kết quả dung hợp so với Bản thảo đơn lẻ tốt nhất	26
4.3.3	Kết quả dung hợp so với từng mô hình đề xuất	26
4.3.4	Kết quả dung hợp so với GPT-4o	27
4.3.5	Ảo giác mô hình và tính xác thực của kết quả	27
4.4	Kết quả Trục C — Đánh giá của con người	28
4.4.1	Thiết lập khảo sát	28
4.4.2	Kết quả nổi bật trên Trục C	28
4.4.3	Tương tác theo nhóm chủ đề	29
4.4.4	Độ đồng thuận giữa các người đánh giá	29
4.5	Phân tích đa trục	29
4.6	Hạn chế phương pháp luận	30
4.7	Tổng kết chương	31
Chương 5:	Kết luận và hướng phát triển	32
5.1	Tóm tắt các đóng góp	32
5.2	Hạn chế của đề tài	32
5.3	Hướng phát triển	33
TÀI LIỆU THAM KHẢO		34
PHỤ LỤC		35

DANH MỤC HÌNH VẼ

3.1	Kiến trúc hệ thống ba dịch vụ của Fiber.	13
3.2	Nguyên lý hoạt động của dịch vụ tóm tắt văn bản.	15
3.3	Kiến trúc pipeline hai lớp MoA tích hợp kết nối phần dư.	16
3.4	Khung đánh giá ba trục được sử dụng để định vị đa chiều chất lượng hệ thống.	18
3.5	Sơ đồ luồng tính toán các chỉ số thuộc Trục A (Khả năng giữ lại nội dung).	19
3.6	Sơ đồ luồng xử lý đánh giá bằng LLM-Judge thuộc Trục B (Chất lượng và Mức độ ưu tiên).	20
3.7	Sơ đồ luồng xử lý và tổng hợp số liệu thống kê thuộc Trục C (Đánh giá của con người).	22

DANH MỤC BẢNG BIỂU

2.1	Thông số cấu hình mặc định của các mô hình được sử dụng	8
4.1	Phân bố số lượng bài báo trong tập dữ liệu thực nghiệm theo danh mục	24
4.2	Trục A — các hệ số overlap so với bài viết nguồn (điểm số càng cao thể hiện bản tóm tắt càng bám sát văn phong từ vựng của bài gốc).	25
4.3	Trục B.1 — điểm số rubric đánh giá bằng LLM-giám khảo (1–5). Sử dụng <code>judge_model = gpt-4o-mini-2024-07-18</code>	26
4.4	Trục B.2a — phán quyết đấu cặp, bản dung hợp (A) đấu với bản thảo tốt nhất (B) trên toàn bộ tập dữ liệu. Các kết quả hòa được tính vào tổng số lượng.	26
4.5	Trục B.2b — bản dung hợp đấu với từng mô hình đề xuất. Kiểm định dấu (sign-test) được thực hiện hai chiều; loại trừ các trường hợp hòa.	27
4.6	Trục B.2c — phán quyết đấu cặp, bản dung hợp (A) so sánh với GPT-4o chạy đơn lẻ (B). Kiểm định dấu thực hiện hai chiều; loại trừ các trường hợp hòa.	27
4.7	Trục B.3 — đánh giá tính xác thực qua quan hệ kéo theo cấp mệnh đề (sử dụng mô hình phán quyết <code>gpt-4o-mini</code>).	28
4.8	Trục C — các chỉ số thống kê mô tả tổng hợp từ người đánh giá, quy mô $n = 192$ kết quả xếp hạng trên 48 tác vụ.	28
4.9	Trục C — sở thích xếp hạng phân nhánh theo nhóm chủ đề. Ký hiệu: F = Bản dung hợp, $4o$ = GPT-4o đơn lẻ, m = Bản thảo <code>gpt-4o-mini</code>	29
4.10	Đối chiếu đa trục, bản dung hợp đối đầu với các mô hình cơ sở.	30

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Chữ viết tắt	Nghĩa đầy đủ / Giải thích
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BLEU	Bilingual Evaluation Understudy — hệ số đo độ chính xác n -gram có hiệu chỉnh
BERT	Bidirectional Encoder Representations from Transformers
BERTScore	Hệ số tương đồng ngữ nghĩa dựa trên nhúng từ ngữ cảnh (sử dụng PhoBERT trong khóa luận này)
CoT	Chain-of-Thought (Chuỗi suy luận từng bước)
CSV	Comma-Separated Values (Dữ liệu phân cách bằng dấu phẩy)
CRUD	Create, Read, Update, Delete (Tạo, Đọc, Cập nhật, Xóa)
DOM	Document Object Model
GPT	Generative Pre-trained Transformer
HF	Hugging Face
JSON	JavaScript Object Notation
JSDOM	JavaScript DOM implementation in Node.js
LLM	Large Language Model (Mô hình ngôn ngữ lớn)
MoA	Mixture-of-Agents — Kiến trúc đa tác nhân phối hợp (Wang et al., 2024)
MV3	Manifest V3 (Đặc tả tiện ích mở rộng Chrome)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
RAG	Retrieval-Augmented Generation (Tạo văn bản tăng cường truy xuất)
RLS	Row-Level Security — Bảo mật cấp hàng (PostgreSQL)
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
SAG	Search-Augmented Generation (Tạo văn bản tăng cường tìm kiếm)
SDK	Software Development Kit (Bộ công cụ phát triển phần mềm)
SSE	Server-Sent Events (Sự kiện đẩy từ máy chủ)
TS	TypeScript
UI	User Interface (Giao diện người dùng)
URL	Uniform Resource Locator (Địa chỉ tài nguyên thống nhất)
UUID	Universally Unique Identifier (Mã định danh duy nhất toàn cầu)
ViT5	Vietnamese Text-to-Text Transfer Transformer
PhoBERT	Mô hình BERT tiền huấn luyện cho tiếng Việt (vinai/phobert-base)

Thuật ngữ	Định nghĩa
Tác nhân đề xuất (Proposer)	LLM ở tầng thứ nhất trong pipeline MoA, có nhiệm vụ tạo ra một bản thảo tóm tắt ứng viên
Tác nhân tổng hợp (Aggregator)	LLM ở tầng thứ hai trong pipeline MoA, có nhiệm vụ dung hợp các bản thảo thành đầu ra cuối cùng

Kết nối phần dư (Residual connection)	Việc đưa trực tiếp bài viết nguồn vào ngữ cảnh của tác nhân tổng hợp để quá trình dung hợp luôn neo vào nội dung gốc, không bị ảo tưởng
Đánh giá rubric	Hình thức LLM-Judge chấm điểm tóm tắt trên nhiều tiêu chí có tên cụ thể theo thang số
Đánh giá từng cặp (Pairwise)	Hình thức LLM-Judge so sánh hai bản tóm tắt A và B, chọn ra bản thắng cuộc
Hệ số Fleiss' κ	Chỉ số đồng thuận giữa các người đánh giá dùng cho dữ liệu phân loại từ ≥ 2 người đánh giá
Kiểm định dấu (Sign test)	Kiểm định phi tham số cho kết quả nhị phân theo từng cặp, sử dụng để kiểm tra tỷ lệ thắng từng cặp
Phân nhóm theo độ dài (Length bucketing)	Phân tầng các phán quyết theo cặp dựa trên tỷ lệ độ dài đầu ra để kiểm soát thiên kiến độ dài
Đồng thuận logic (Entailment)	Quan hệ logic: giả thuyết được hỗ trợ bởi tiền đề; sử dụng để đánh giá tính xác thực cấp mệnh đề

MỞ ĐẦU

Tính cấp thiết của đề tài

Tin tức trực tuyến tiếng Việt đã trở thành phương tiện truyền thông tin công cộng chủ yếu, với hàng chục triệu bài báo được đăng tải mỗi năm trên các tờ báo lớn như *tuoitre.vn*, *thanhnien.vn*, *tienphong.vn*, *vietnamnet.vn* và nhiều tờ khác. Khối lượng thông tin khổng lồ này tạo ra hai nhu cầu song song cho người đọc. Nhu cầu đầu tiên là nén thông tin: một bản tóm tắt súc tích, đáng tin cậy giúp người đọc có thể nắm bắt nội dung bài báo dài chỉ trong vài giây. Nhu cầu thứ hai là xác thực thông tin: kiểm tra xem các mệnh đề chính trong bài báo có được các nguồn uy tín khác xác nhận hay không, đặc biệt trong bối cảnh tin giả, tiêu đề giật gân và các bài viết chỉ phản ánh một phần sự thật lan truyền song song cùng các bài báo chính xác.

Hiện nay, các hệ thống tóm tắt tiếng Việt xây dựng dựa trên một Mô hình ngôn ngữ lớn đơn lẻ vẫn cho ra kết quả không ổn định — đôi khi quá dài, đôi khi quá sát từ ngữ gốc, thậm chí đôi khi bịa đặt thông tin. Một hướng nghiên cứu gần đây, Mixture-of-Agents (MoA) của Wang et al. [8], lập luận rằng nhiều LLM có thể được kết hợp trong một kiến trúc phân cấp tác nhân gồm nhiều tác nhân đề xuất và tổng hợp để tạo ra kết quả vượt trội so với bất kỳ mô hình đơn lẻ nào trên các thang đánh giá. Tuy nhiên, liệu phương pháp này có thể áp dụng với bài toán tóm tắt tiếng Việt có neo ngữ cảnh gốc — nơi hệ thống phải trung thực với bài báo nguồn thay vì trả lời tự do — hay không, vẫn là câu hỏi chưa được giải đáp trong các nghiên cứu xử lý ngôn ngữ tự nhiên tiếng Việt.

Một vấn đề sâu hơn thúc đẩy khóa luận này: các hệ số đo lường phổ biến nhất trong nghiên cứu tóm tắt tiếng Việt — ROUGE [3], BLEU [6] và BERTScore [10] được tính toán dựa vào đối chiếu so với bài báo gốc — đo độ trùng lặp, không đo chất lượng. Các thang điểm này đánh giá cao các bản tóm tắt tái sử dụng cụm từ từ bài gốc và chấm điểm thấp các bản tóm tắt diễn giải lại hoặc rút gọn mạnh. Một tác nhân tổng hợp trong pipeline MoA nếu được triển khai đúng cách sẽ tổng hợp các bản thảo từ các tác nhân đề xuất thành bản tóm tắt hoàn chỉnh, về nguyên lý sẽ đạt điểm thấp hơn trên các hệ số này so với bản tóm tắt sao chép cụm từ đơn thuần. Nếu nghiên cứu tóm tắt tiếng Việt muốn áp dụng các hệ thống đa tác nhân đề xuất và tổng hợp, lĩnh vực này cần một phương pháp luận đánh giá không có thiên kiến cấu trúc bất lợi cho các hệ thống đó.

Ý nghĩa khoa học và thực tiễn

Khóa luận đóng góp ý nghĩa khoa học bằng việc phát triển một *khung đánh giá ba trục* kết hợp: (i) các hệ số độ phủ nội dung so với bài gốc, (ii) đánh giá chất lượng bởi LLM và xếp hạng theo cặp, và (iii) xếp hạng mù bởi con người với chỉ số đồng thuận giữa các người đánh giá. Khóa luận sử dụng khung đó để chỉ ra, bằng chứng thực nghiệm trên dữ liệu tiếng Việt, một hạn chế cấu trúc của các hệ số độ phủ đối với bài toán tóm tắt kiểu tổng hợp. Hạn chế này đã được đề cập gián tiếp trong các nghiên cứu tiếng Anh [8, 11] nhưng chưa được nghiên cứu tường minh cho tiếng Việt.

Đối với khía cạnh thực tiễn, khóa luận cung cấp một sản phẩm tiện ích trình duyệt hoàn chỉnh có tên Fiber, mà bất kỳ người đọc báo Việt Nam nào cũng có thể cài đặt trên trình duyệt dựa trên Chromium. Fiber nhúng một thanh sidebar tự động xuất hiện khi người đọc báo truy cập bảy tên miền báo chí tiếng Việt lớn, tóm tắt bài báo theo thời gian thực bằng một LLM do người dùng chọn (hoặc pipeline MoA dung hợp), bên cạnh đó là chức năng hộp kiểm chứng thông tin so với bằng chứng từ web trực tiếp thông qua API tìm kiếm Tavily. Toàn bộ hệ thống — một backend Next.js, một tiện ích mở

rộng trình duyệt Plasmio, và một dịch vụ BERTScore Python — đều được phát hành nguồn mở.

Mục tiêu nghiên cứu

Khoá luận này hướng tới ba mục tiêu song song, bao trùm cả chiều rộng của hệ thống (từ giao diện đến hạ tầng) và chiều sâu học thuật (từ thiết kế pipeline đến đánh giá hệ số):

- Thiết kế và xây dựng hệ thống tiện ích mở rộng trình duyệt đầu-cuối hoàn chỉnh, có khả năng tóm tắt bài báo tiếng Việt theo thời gian thực, hỗ trợ nhiều nhà cung cấp LLM (OpenAI, Anthropic, Google) và nhiều cơ chế phân loại định tuyến.
- Áp dụng pipeline Mixture-of-Agents của Wang et al. (2024) cho bài toán tóm tắt tiếng Việt có neo ngữ cảnh gốc, bao gồm một kết nối phần dư bài viết nguồn vào câu lệnh của tác nhân tổng hợp.
- Đề xuất một khung đánh giá ba trục — khả năng giữ lại nội dung (Trục A), chất lượng kết quả tóm tắt đánh giá bởi LLM (Trục B), và xếp hạng con người với chỉ số đồng thuận (Trục C) — đồng thời sử dụng khung đó để so sánh dung hợp MoA với các mô hình đơn lẻ cơ sở trên tập dữ liệu tiếng Việt cân bằng chủ đề.

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của khoá luận tập trung vào:

- Bài toán tóm tắt tự động văn bản (Text Summarization), cụ thể là xử lý và tổng hợp tin tức báo chí tiếng Việt.
- Kiến trúc hệ thống đa tác nhân (Multi-Agent System) ứng dụng các mô hình ngôn ngữ lớn (LLM) thương mại và các mô hình ngôn ngữ đặc thù cho tiếng Việt trong việc phân loại, định tuyến và đánh giá ngữ nghĩa văn bản.

Phạm vi nghiên cứu của khoá luận được giới hạn trong các biên giới cụ thể sau:

- Phạm vi dữ liệu: Thực nghiệm đánh giá hệ thống được giới hạn trên tập dữ liệu gồm 154 bài báo tiếng Việt được thu thập từ trang tin điện tử *tienphong.vn*, phân bổ cân bằng theo 5 chủ đề: thời sự, pháp luật, kinh tế, giáo dục và văn hóa. Các nguồn báo khác bao gồm *tuoitre.vn*, *thanhnien.vn*, *vietnamnet.vn*, *laodong.vn*, *vtv.vn* và *nld.com.vn* chỉ được sử dụng trong giai đoạn khảo sát, phân tích dữ liệu ban đầu.
- Phạm vi công nghệ và giới hạn kỹ thuật: Đề tài giới hạn ở việc khai thác, phối hợp năng lực của các LLM thương mại trên đám mây làm tác nhân đề xuất (GPT-4o-mini, Claude Haiku 4.5, Gemini 2.5 Flash) và tác nhân tổng hợp (GPT-4o), kết hợp các mô hình tiếng Việt có sẵn (ViT5 [4], PhoBERT [5]) để định tuyến và đánh giá. Khoá luận không thực hiện huấn luyện lại hoặc tinh chỉnh sâu các mô hình nền tảng từ đầu.

Phương pháp nghiên cứu

Khoá luận áp dụng phương pháp thực nghiệm so sánh. Cùng một tập 154 bài báo được tóm tắt bởi năm phương pháp (ba tác nhân đề xuất riêng lẻ, đầu ra dung hợp MoA, và mô hình đơn lẻ cơ sở lựa chọn bản thảo tốt nhất), và 770 bản tóm tắt thu được được đánh giá theo ba trục. Trục A sử dụng ROUGE-1/2/L, BLEU, BERTScore (với PhoBERT) và tỷ lệ nén; Trục B sử dụng rubric 5 chiều theo

FLASK [9], điểm tuyệt đối kiểu MT-Bench [11], đánh giá so sánh từng cặp kiểu AlpacaEval có ngẫu nhiên hóa vị trí [1], và bộ phân loại tính xác thực ở cấp độ mệnh đề; Trục C sử dụng giao diện xếp hạng mù $K = 3$ để tổ chức các bài đánh giá và thu thập dữ liệu. Các kiểm định thống kê bao gồm kiểm định dấu hai chiều (loại trừ hòa) cho tỷ lệ thắng từng cặp và Fleiss' κ [2] cho đồng thuận giữa các người đánh giá; thiên kiến độ dài được kiểm soát bằng phương pháp phân nhóm đơn giản hóa của Dubois et al. [1].

Bố cục khóa luận

Khoá luận được tổ chức như sau:

Chương 1 — Tổng quan: Giới thiệu bài toán tóm tắt tin tức, kỹ thuật Mixture-of-Agents, và các công trình liên quan trong nghiên cứu tiếng Việt cũng như quốc tế, từ đó xác định khoảng trống mà khoá luận sẽ khai thác.

Chương 2 — Cơ sở lý thuyết: Trình bày các kiến trúc LLM được sử dụng trong hệ thống, ba dòng hệ số đánh giá (độ phủ, LLM-Judge, xếp hạng con người), phương pháp luận tính xác thực, và các công nghệ để xây dựng tiện ích mở rộng trình duyệt cùng các dịch vụ backend.

Chương 3 — Thiết kế và xây dựng hệ thống: Trình bày phân tích yêu cầu, kiến trúc ba dịch vụ, lớp trừu tượng hóa LLM đa nhà cung cấp, pipeline MoA (đóng góp kỹ thuật), khung đánh giá ba trục (đóng góp phương pháp luận), lược đồ cơ sở dữ liệu, và giao diện người dùng.

Chương 4 — Thực nghiệm và đánh giá: Báo cáo kết quả theo ba trục trên tập dữ liệu 154 bài báo, bao gồm kết quả từng cặp nổi bật nhất, phân tích theo chủ đề, diễn giải nghiên cứu con người, tam giác hóa đa trục và nêu lên các hạn chế của phương pháp luận.

Chương 5 — Kết luận và định hướng: tóm tắt các đóng góp, hạn chế và hướng phát triển tương lai; hai phụ lục trình bày ví dụ minh họa và thử nghiệm câu lệnh của tác nhân tổng hợp.

Chương 1

Giới thiệu bài toán

Chương này đặt nền móng cho toàn bộ khóa luận bằng việc giới thiệu bài toán trọng tâm — tóm tắt văn bản tin tức tiếng Việt — cùng với kỹ thuật Mixture-of-Agents (MoA) được khóa luận lựa chọn làm phương pháp tiếp cận chính. Trước tiên, Mục 1.1 trình bày định nghĩa bài toán tóm tắt văn bản và các thách thức đặc thù khi áp dụng cho tiếng Việt; Mục 1.2 giới thiệu pipeline MoA với thiết kế phân tầng đa tác nhân; và Mục 1.3 khảo sát các công trình liên quan trong nghiên cứu tiếng Việt lần quốc tế, từ đó xác định ba khoảng trống nghiên cứu mà khóa luận nhắm tới khai thác.

1.1 Bài toán tóm tắt văn bản tự động

Tóm tắt văn bản tự động là bài toán tạo ra một phiên bản ngắn hơn của văn bản nguồn mà vẫn bảo toàn thông tin thiết yếu. Cho một tài liệu đầu vào D , bộ tóm tắt f tạo ra bản tóm tắt $S = f(D)$ sao cho $|S| \ll |D|$ và S giữ lại các dữ kiện then chốt của D .

Các hệ thống tóm tắt thường được phân loại theo hai trục:

- Trích xuất so với trừu tượng hóa: Hệ thống trích xuất chọn lựa các câu (hoặc đoạn câu) hiện có từ văn bản gốc. Hệ thống trừu tượng hóa tạo ra văn bản mới và có thể diễn giải lại, sắp xếp lại thứ tự hoặc kết hợp các ý tưởng. Các bộ tóm tắt dựa trên LLM hiện đại chủ yếu là kiểu trừu tượng hóa.
- Đơn tài liệu so với đa tài liệu: Hệ thống đơn tài liệu tóm tắt một bài báo riêng lẻ; hệ thống đa tài liệu tổng hợp thông tin từ nhiều bài báo liên quan. Hệ thống trong khóa luận này là đơn tài liệu, nhưng pipeline MoA có thể được hiểu như một bộ tổng hợp đa nguồn suy biến, trong đó “nhiều nguồn” chính là các bản thảo LLM khác nhau của cùng một bài báo.

Tiếng Việt đặt ra ba thách thức cho việc đánh giá chất lượng kết quả tóm tắt:

- Phân đoạn từ: Tiếng Việt được viết với khoảng trắng giữa các âm tiết, không phải giữa các từ; một từ khái niệm có thể kéo dài hai đến ba âm tiết (*tóm tắt*, *kiểm chứng*). Các hệ số overlap từ vựng được tính trên đơn vị token khoảng trắng sẽ hệ thống hóa việc không ghi nhận công cho các cách diễn đạt lại tái cấu trúc thuật ngữ đa âm tiết.
- Dấu phụ và thanh điệu: Tiếng Việt có sáu thanh từ vựng, được mã hóa dưới dạng dấu phụ trên nguyên âm; kho từ vựng của bộ mã hóa phân mảnh các ký tự có dấu sẽ mất đi độ chi tiết ngữ nghĩa.
- Khan hiếm corpus đánh giá: So với tiếng Anh (CNN/DailyMail, XSum, MultiNews), tiếng Việt không có bộ đánh giá tóm tắt được chú thích bởi con người so với các bản tóm tắt tham chiếu. Đây là lý do thực tế khiến ROUGE/BLEU/ BERTScore trong nghiên cứu tiếng Việt thường được tính so với bài báo gốc, không phải so với bản tóm tắt tham chiếu của con người — một lưu ý phương pháp luận sẽ được đề cập lại ở Chương 4.

Bên cạnh nhu cầu đọc thông tin nhanh, người đọc ngày nay cũng ngày một nâng cao nhận thức về tính xác thực của thông tin. Các tiêu đề giật gân, trích dẫn phiến diện và thông tin sai lệch lan truyền trên mạng xã hội và các tổng hợp tin tức ngày càng tinh vi và khó phân biệt. Kiểm chứng thủ công không

đủ khả năng đáp ứng so với quy mô thông tin hiện tại; một công cụ hỗ trợ được tích hợp ngay trong trình duyệt, có khả năng gắn cờ các mệnh đề không có căn cứ, ngày càng trở nên có giá trị và ngày càng trở nên quan trọng hơn khi được gắn liền với bài toán tóm tắt tin tức.

1.2 Pipeline Mixture-of-Agents (MoA)

Wang et al. đề xuất Mixture-of-Agents vào năm 2024 [8]. Quan sát thực nghiệm trung tâm là một LLM đóng vai trò tác nhân tổng hợp cho ra câu trả lời tốt hơn khi được cung cấp nhiều câu trả lời ứng viên từ các LLM khác được coi là tác nhân đề xuất — kể cả khi các LLM kia riêng lẻ yếu hơn chính tác nhân tổng hợp. Các tác giả gọi đây là khả năng hợp tác của các LLM.

MoA là một cấu trúc phân tầng. Tầng ℓ gồm n tác nhân $\{A_{\ell,1}, \dots, A_{\ell,n}\}$; mỗi tác nhân ở tầng $\ell + 1$ nhận lời nhắc cùng với đầu ra của tất cả các tác nhân ở tầng ℓ . Về mặt hình thức, tác nhân i ở tầng $\ell + 1$ tạo ra

$$y_{\ell+1,i} = A_{\ell+1,i}([y_{\ell,1}, y_{\ell,2}, \dots, y_{\ell,n}] + x),$$

trong đó x là lời nhắc của người dùng và $+$ biểu thị phép nối chuỗi. Trong phiên bản hai tầng (được sử dụng trong khóa luận này), tầng 1 là tầng tác nhân đề xuất và tầng 2 là một tác nhân tổng hợp duy nhất.

Trên bộ đánh giá AlpacaEval 2.0, một cấu hình MoA với sáu tác nhân đề xuất mã nguồn mở và một tác nhân tổng hợp đạt tỷ lệ thắng LC(length-controlled) là 65,1%, vượt qua GPT-4o (57,5%) theo cùng giao thức đánh giá. Hiệu suất tăng đơn điệu theo số lượng tầng và số lượng tác nhân đề xuất mỗi tầng (Bảng 3–4 của [8]).

Bài báo MoA đánh giá trên các bộ đánh giá tuân thủ hướng dẫn (AlpacaEval, MT-Bench, FLASK) trong đó LLM-Judge — không phải độ overlap với bất kỳ văn bản nguồn nào — là tiêu chuẩn đánh giá. Liệu MoA có thể áp dụng được đối với trường hợp tóm tắt có neo ngữ cảnh gốc (nơi tồn tại một bài báo nguồn và có thể đo được độ overlap), và kết quả tương tự có thể đạt được đối với tiếng Việt hay không, chính là câu hỏi thực nghiệm mà khóa luận này trả lời.

1.3 Các công trình liên quan và khoảng trống nghiên cứu

Khoá luận đồng thời cũng giới thiệu các công trình nghiên cứu tương tự đã xuất hiện cũng như xác định khoảng trống nghiên cứu:

Google News Việt Nam và Báo Mới cung cấp tin tức tổng hợp với các đoạn mô tả ngắn, nhưng các đoạn đó là trích dẫn trực tiếp từ đoạn dẫn đầu bài, không phải bản tóm tắt biên tập trừu tượng. Nghiên cứu học thuật về tóm tắt tiếng Việt đã sử dụng ViT5 [4] cho nhiệm vụ sinh văn bản tóm tắt trừu tượng, được đánh giá hoàn toàn bằng thang điểm ROUGE so với bản tóm tắt tham chiếu (khi có) hoặc so với bài báo gốc (phổ biến hơn).

ClaimBuster (UT Arlington) được xây dựng tập trung cho các bài phát biểu chính trị tiếng Anh; trong khi Google Fact Check Tools API tổng hợp các phán quyết từ các tổ chức kiểm chứng thông tin hiện có. Cả hai đều không nhắm vào tiếng Việt, và cả hai đều không hoạt động ở cấp bài báo cho người đọc thông thường.

Các tiện ích TLDR This, Summari và Reader Mode nhúng bản tóm tắt trong trang trên các trang web tùy ý nhưng ưu tiên tiếng Anh và không cung cấp tính năng kiểm chứng thông tin. NewsGuard và Bias Buddy đánh giá độ tin cậy của nhà xuất bản, không phải bài báo riêng lẻ, và dựa trên đánh giá thủ công thay vì xác minh từng bài báo.

Zheng et al. [11] giới thiệu MT-Bench và phương pháp Chatbot Arena, chứng minh rằng một LLM mạnh (GPT-4) đạt mức độ đồng thuận khoảng $\sim 80\%$ so với thị hiếu của con người (xấp xỉ mức mà hai người đánh giá đồng ý với nhau). FLASK [9] bổ trợ phương pháp này thông qua đánh giá rubric chi tiết theo nhiều thang điểm khác nhau. AlpacaEval [1] bổ sung thêm kỹ thuật ngẫu nhiên hóa vị trí và kiểm soát độ dài để giảm thiểu hai thiên kiến đã biết của LLM-as-Judge. Module đánh giá Trục B của khóa luận này được xây dựng trên các phương pháp nêu trên.

Khoá luận phát hiện các công trình được kể trên chưa có công trình nào trước đây (i) áp dụng Mixture-of-Agents cho tiếng Việt, (ii) kết hợp việc triển khai sản phẩm dưới dạng tiện ích trình duyệt với kiểm chứng thông tin và tóm tắt trên tin tức tiếng Việt, hoặc (iii) đối chiếu một cách tường minh ba phương pháp đánh giá: độ chùng chéo, LLM-Judge và đánh giá con người trong một khuôn khổ *ba trục* duy nhất cho bài toán tóm tắt tiếng Việt. Khóa luận này sẽ nhắm tới việc khai thác và lấp đầy ba khoảng trống nghiên cứu đó.

1.4 Tổng kết chương

Chương này đã thiết lập bức tranh toàn cảnh cho khóa luận thông qua ba nội dung chính. Thứ nhất, bài toán tóm tắt văn bản tự động được trình bày với các đặc thù của tiếng Việt bao gồm phân đoạn từ đa âm tiết, dấu phụ thanh điệu và sự khan hiếm corpus đánh giá có chú thích bởi con người. Thứ hai, kỹ thuật Mixture-of-Agents được giới thiệu với thiết kế phân tầng, trong đó tầng tác nhân đề xuất tạo ra các bản thảo độc lập và tầng tác nhân tổng hợp dung hợp chúng thành bản tóm tắt chất lượng cao hơn — một kết quả đã được chứng minh trên các bộ đánh giá quốc tế nhưng chưa được kiểm chứng cho tiếng Việt. Thứ ba, qua khảo sát các công trình liên quan, chương đã xác định ba khoảng trống nghiên cứu: chưa có công trình nào áp dụng MoA cho tiếng Việt, kết hợp tóm tắt với kiểm chứng thông tin trong một tiện ích trình duyệt, hay đối chiếu tường minh ba phương pháp đánh giá trong một khuôn khổ thống nhất cho bài toán tóm tắt tiếng Việt. Các nền tảng lý thuyết cần thiết để xây dựng hệ thống lấp đầy những khoảng trống này sẽ được trình bày chi tiết trong Chương 2.

Chương 2

Cơ sở lý thuyết

Chương này xây dựng nền tảng lý thuyết cho toàn bộ hệ thống được triển khai trong Chương 3 và các thực nghiệm đánh giá trong Chương 4. Mục 2.1 trình bày kiến trúc Transformer cùng ba dòng mô hình ngôn ngữ lớn và liệt kê cụ thể các mô hình được sử dụng trong hệ thống. Mục 2.2 là phần trọng tâm lý thuyết của chương, trình bày chi tiết ba trục đánh giá chất lượng tóm tắt. Mỗi khái niệm lý thuyết được gắn trực tiếp với một lựa chọn thiết kế cụ thể trong hệ thống.

2.1 Các mô hình ngôn ngữ lớn

2.1.1 Kiến trúc Transformer

Kiến trúc Transformer [7] thay thế các mô hình chuỗi hồi quy và tích chập cho các bài toán ngôn ngữ tự nhiên dựa trên cơ chế chú ý. Với truy vấn Q , khóa K và giá trị V , chú ý tích vô hướng có tỷ lệ được định nghĩa như sau:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V,$$

trong đó d_k là chiều của khóa. Chú ý đa đầu chiếu Q, K, V vào h không gian con, chạy chú ý trong từng không gian, và nối kết quả lại, cho phép mô hình chú ý đến các quan hệ vị trí khác nhau cùng lúc.

Các LLM hiện đại thuộc ba dòng kiến trúc như sau:

- Các mô hình chỉ bộ mã hóa (encoder-only) như BERT và PhoBERT [5] tạo ra các embedding ngữ cảnh cho các token đầu vào; chúng được sử dụng trong khóa luận này như xương sống embedding cho BERTScore (Mục 2.2.3).
- Các mô hình chỉ bộ giải mã (decoder-only) như GPT, Claude và Gemini tạo văn bản theo hướng tự hồi quy và được sử dụng làm tác nhân đề xuất và tác nhân tổng hợp của pipeline MoA (Chương 3).
- Các mô hình bộ mã hóa–bộ giải mã (encoder-decoder) như T5 và ViT5 [4] mã hóa đầu vào và điều kiện hóa việc tạo của bộ giải mã trên đó; ViT5 được sử dụng làm phương án dự phòng định tuyến cho các đầu vào tiếng Việt ngắn.

2.1.2 Các mô hình được sử dụng

Hệ thống của khóa luận hiện tại đang sử dụng các mô hình sau:

- **GPT-4o** (OpenAI, phiên bản 2024-08-06) — tác nhân tổng hợp trong pipeline MoA và mô hình đơn lẻ cơ sở mạnh nhất trong phạm vi khóa luận.
- **GPT-4o-mini** (OpenAI, phiên bản 2024-07-18) — tác nhân đề xuất và mô hình giám khảo; LLM-Judge mặc định trong Trục B.
- **Claude Haiku 4.5** (Anthropic) — tác nhân đề xuất; được đưa vào để mở rộng nhóm tác nhân đề xuất ra ngoài OpenAI.

- **Gemini 2.5 Flash** (Google) — tác nhân đề xuất; dòng thứ ba được sử dụng trong MoA.
- **ViT5-large** (VinAI) — phương án dự phòng định tuyến cho các đầu vào tiếng Việt ngắn trong lớp định tuyến dựa trên độ phức tạp.
- **PhoBERT-base** (VinAI) — bộ mã hóa ngữ cảnh cho BERTScore.

Tất cả mô hình trên khi gọi qua giao diện API đều được thiết lập ở các thông số cấu hình mặc định của nhà cung cấp. Chi tiết các thông số mặc định cụ thể cho từng mô hình được tổng hợp trong Bảng 2.1.

Bảng 2.1: Thông số cấu hình mặc định của các mô hình được sử dụng

Mô hình	Thông số cấu hình mặc định
GPT-4o	Temperature = 1.0, Top- p = 1.0, Frequency Penalty = 0.0, Presence Penalty = 0.0
GPT-4o-mini	Temperature = 1.0, Top- p = 1.0, Frequency Penalty = 0.0, Presence Penalty = 0.0
Claude Haiku 4.5	Temperature = 1.0, Top- p = 1.0
Gemini 2.5 Flash	Temperature = 1.0, Top- p = 0.95
ViT5-large	Chiến lược giải mã mặc định (Greedy decoding)
PhoBERT-base	Không áp dụng (N/A — Trích xuất embedding làm vector đặc trưng)

Bên cạnh các mô hình chính, các mô hình khác được tinh chỉnh suy luận như OpenAI o1-mini đòi hỏi cơ chế xử lý đặc thù: các tham số temperature, top- p và penalty không được hỗ trợ, và giao thức streaming khác với các mô hình chat-completion thông thường. Tầng dịch vụ trong Chương 3 sẽ trừu tượng hóa các khác biệt này để tất cả 14 mô hình được hỗ trợ có thể được chọn hoán đổi cho nhau trong quá trình thực thi.

2.2 Cơ sở đánh giá chất lượng tóm tắt

2.2.1 Độ phủ nội dung (Trục A)

(a) ROUGE

ROUGE [3] (Recall-Oriented Understudy for Gisting Evaluation) đo độ overlap n -gram và chuỗi con chung dài nhất giữa bản tóm tắt ứng viên C và tham chiếu R . Gọi g_n là tập hợp các n -gram:

$$\text{ROUGE-}n_{\text{recall}} = \frac{|g_n(C) \cap g_n(R)|}{|g_n(R)|},$$

$$\text{ROUGE-}n_{\text{prec}} = \frac{|g_n(C) \cap g_n(R)|}{|g_n(C)|},$$

và $\text{ROUGE-}n_{F1}$ là trung bình điều hòa của hai giá trị trên. ROUGE-1 và ROUGE-2 sử dụng đơn gram và hai gram tương ứng; ROUGE-L dựa trên chuỗi con chung dài nhất và thưởng cho độ overlap theo thứ tự.

ROUGE được tính trên các token phân tách bằng khoảng trắng. Một từ tiếng Việt như *kiểm chứng* là hai token, và một cách diễn đạt lại dùng từ *thẩm định* để thay thế sẽ không được tính điểm, mặc dù ý nghĩa hoàn toàn tương đương. Đây là một lưu ý khi sử dụng ROUGE cho nghiên cứu tiếng Việt.

(b) **BLEU**

BLEU [6] là hệ số thiên về độ chính xác, ban đầu được thiết kế cho dịch máy. Với một tập n -gram, độ chính xác có hiệu chỉnh p_n cắt bớt số đếm ở số đếm tham chiếu tối đa; BLEU kết hợp $p_1, \dots, p_4$ như một trung bình nhân có trọng số và nhân với hệ số phạt ngắn BP :

$$\text{BLEU} = BP \cdot \exp\left(\sum_{n=1}^4 w_n \log p_n\right), \quad BP = \min(1, \exp(1 - \frac{r}{c})),$$

trong đó r là độ dài tham chiếu, c là độ dài ứng viên và $w_n = 1/4$. Tương tự ROUGE, BLEU cũng mắc điểm yếu về sự thiếu ổn định trong việc phân tách token khi áp dụng với tiếng Việt.

(c) **BERTScore (với PhoBERT)**

BERTScore [10] thay thế khớp n -gram bằng độ tương đồng cosine giữa các nhúng ngữ cảnh. Với mỗi token c_i trong ứng viên, token khớp tốt nhất r_j trong tham chiếu đóng góp một giá trị $\cos(\mathbf{e}(c_i), \mathbf{e}(r_j))$ vào điểm Precision của BERTScore; điểm Recall được định nghĩa đối xứng. Điểm cuối cùng F_{BERT} là trung bình điều hòa của hai giá trị này.

Trong khóa luận này, mô hình embedding được sử dụng là `vinai/phobert-base` với đầu vào được cắt ngắn xuống còn 256 token trước khi tính điểm, vừa phù hợp cửa sổ ngữ cảnh của mô hình vừa chuẩn hóa chi phí một lần gọi đánh giá. BERTScore nắm bắt được sự tương đồng ngữ nghĩa mà các hệ số overlap bỏ sót, nhưng vẫn chầm chậm so với bài báo gốc, do đó nó kế thừa cùng một ý nghĩa về khả năng lưu trữ nội dung tương tự như ROUGE và BLEU.

(d) **Tỷ lệ nén**

Tỷ lệ nén là $|S|/|D|$ biểu thị theo phần trăm, trong đó $|S|$ và $|D|$ là số token của bản tóm tắt và bài gốc. Đây không phải hệ số chất lượng, nhưng nó giải thích *tại sao* các hệ số overlap hoạt động như vậy: một bản tóm tắt được tạo ra với tỷ lệ nén 30% có ít từ, cụm từ dễ khớp hơn một bản tóm tắt chắp vá ở mức 50%, và do đó điểm trùng khớp sẽ giảm xuống ngay cả khi chất lượng thực tế của bản tóm tắt tăng lên.

Lưu ý quan trọng nhất của khóa luận này, được phát biểu lại chính thức như sau: ROUGE, BLEU và BERTScore được tính so với bài báo gốc đo khả năng giữ lại nội dung, không đo chất lượng tóm tắt. Khi hệ thống được phép (hoặc khuyến khích) diễn giải lại, một bản tóm tắt được biên tập kỹ lưỡng nhằm cải thiện độ mạch lạc sẽ có khả năng làm giảm độ trùng khớp token. Wang et al. [8] bỏ qua vấn đề này bằng cách sử dụng LLM-Judge làm tiêu chuẩn đánh giá; lựa chọn tương tự được thực hiện trong Trục B của khóa luận này.

2.2.2 Phương pháp luận LLM-Judge (Trục B)

(a) **Đánh giá rubric (theo FLASK)**

Một LLM-Judge rubric chấm điểm bản tóm tắt theo nhiều chiều có tên trên thang điểm nguyên. Theo FLASK [9], khóa luận này sử dụng năm chiều trên thang 1–5: *tính trung thực (faithfulness)*, *độ bao phủ (coverage)*, *độ trôi chảy (fluency)*, *tính súc tích (conciseness)* và *tổng thể (overall)*. LLM-Judge được yêu cầu trả về kết quả dưới định dạng JSON bao gồm năm điểm số kèm theo một câu giải thích cho từng tiêu chí.

(b) **Chấm điểm tuyệt đối (theo MT-Bench)**

Giao thức MT-Bench [11] yêu cầu LLM-Judge cho một điểm số tổng thể nguyên duy nhất trong $\{1, 2, \dots, 10\}$. Cách này nhanh hơn rubric tuy nhiên lại không đánh giá chi tiết kết quả; vì thế được sử dụng bổ trợ cho rubric.

(c) **So sánh từng cặp (theo AlpacaEval)**

Một LLM-Judge được hiển thị hai bản tóm tắt ứng viên A và B cho cùng bài gốc và được yêu cầu chọn bên thắng (hoặc hòa). Kết quả thực nghiệm của chính khóa luận này được trình bày dưới dạng so sánh cặp, bởi vì độ đồng thuận trong phương pháp đánh giá từng cặp cao hơn so với phương pháp chấm điểm tuyệt đối. Hai chi tiết giao thức quan trọng:

- Ngẫu nhiên hóa vị trí: Các LLM-Judge có xu hướng thiên vị đối với ứng viên trình bày đầu tiên. Do đó, mỗi lần gọi từng cặp gán ngẫu nhiên hai bản tóm tắt vào vị trí A và B , và ánh xạ vị trí được ghi lại để ứng viên thắng được ghi nhận chính xác.
- Ý nghĩa thống kê kiểm định dấu: Với w thắng trên n phán quyết quyết định (loại trừ hòa), giá trị p của kiểm định dấu hai chiều là

$$p = 2 \cdot \Pr[X \geq \max(w, n - w) \mid X \sim \text{Bin}(n, 0,5)],$$

là xác suất của một kết quả ít nhất cực đoan như kết quả quan sát được dưới $H_0 : P(A \text{ thắng}) = 0,5$. Trong toàn bộ khóa luận này, $p < 0,05$ được coi là ngưỡng “khó có thể là ngẫu nhiên”.

(d) **Tỷ lệ thắng có kiểm soát độ dài (Dubois 2024)**

Các LLM-Judge có xu hướng thiên vị các phản hồi dài hơn [1]. Để kiểm soát điều này, các phán quyết từng cặp được phân nhóm theo tỷ lệ độ dài $|A|/|B|$:

- $|A|/|B| < 0,85$ — A ngắn hơn nhiều;
- $0,85 \leq |A|/|B| \leq 1,15$ — độ dài tương đương;
- $|A|/|B| > 1,15$ — A dài hơn nhiều.

Tỷ lệ thắng phân nhóm theo độ dài lấy trung bình các tỷ lệ thắng trong từng nhóm thỏa mãn số đếm tối thiểu (MIN_BUCKET_N = 5). Nếu tỷ lệ thô và tỷ lệ phân nhóm đồng ý với nhau, thiên kiến độ dài của LLM-Judge bị bác bỏ và không ảnh hưởng đến kết quả.

(e) **Đánh giá tính xác thực**

Tính xác thực được xử lý như một bài toán nhị phân trên từng mệnh đề. Cho một bản tóm tắt S và bài gốc D , quá trình đánh giá tính xác thực đi qua các công đoạn:

- Phân tách mệnh đề: Phân rã S thành các mệnh đề nhỏ $\{c_1, \dots, c_k\}$ thông qua một lần gọi LLM có đầu ra có cấu trúc.
- Phân loại chấp thuận: Phân loại mỗi c_j thành $\{\text{được xác nhận}, \text{bị bác bỏ}, \text{không đề cập}\}$ so với D , sử dụng `gpt-4o-mini` với lược đồ JSON ràng buộc.
- Tổng hợp: Báo cáo tỷ lệ xác nhận $|\{c_j : \text{được xác nhận}\}|/k$, số lượng mệnh đề bị bác bỏ (ảo giác thông tin), và lưu trữ các mệnh đề mâu thuẫn nguyên văn để kiểm tra thủ công.

Một bản tóm tắt với tỷ lệ chính xác $> 95\%$ và không có ảo giác thông tin được coi là trung thực ở cấp độ mệnh đề; thực nghiệm trong Chương 4 báo cáo cả giá trị trung bình và trường hợp xấu nhất cho từng phương pháp tiếp cận.

2.2.3 Đánh giá bởi con người (Trục C)

(a) **Xếp hạng mù K chiều**

Trục C sử dụng xếp hạng ẩn danh K lựa chọn. Với mỗi bài báo, $K = 3$ bản tóm tắt ứng viên (bản dung hợp, GPT-4o đơn lẻ và một bản thảo tác nhân đề xuất) được trình bày cho người đánh giá dưới dạng *Bản A*, *Bản B*, *Bản C*, với danh tính mô hình bị ẩn. Người đánh giá kéo thả các ứng viên vào thứ tự từ tốt nhất đến kém nhất và viết một câu giải thích bằng tiếng Việt cho mỗi ứng viên.

(b) **Fleiss’ Kappa**

Fleiss’ κ [2] mở rộng Cohen’s κ cho ≥ 3 người đánh giá. Với N mẫu, n người đánh giá mỗi mẫu và k danh mục, $\kappa = (P - P_e)/(1 - P_e)$, trong đó P là mức đồng thuận trung bình theo từng mẫu (trên các cặp người đánh giá) và P_e là mức đồng thuận kỳ vọng ngẫu nhiên kỳ vọng dựa trên tần suất biên của các nhãn.

Các mức phân giải Landis–Koch được sử dụng trong khóa luận này:

$\kappa < 0$	tệ hơn ngẫu nhiên
0,00–0,20	đồng thuận rất ít
0,21–0,40	đồng thuận vừa phải
0,41–0,60	đồng thuận trung bình
0,61–0,80	đồng thuận đáng kể
0,81–1,00	đồng thuận gần như tuyệt đối

Với dữ liệu xếp hạng, κ được tính trên các nhãn theo vị trí: với mỗi cặp (mục, hạng), “nhãn phân loại” được gán bởi một người đánh giá là ứng viên nhận hạng đó.

2.3 Tổng kết chương

Chương này đã cung cấp toàn bộ nền tảng lý thuyết cần thiết để hiểu và đánh giá hệ thống Fiber. Về mặt mô hình, chương đã trình bày kiến trúc Transformer và ba dòng LLM, trong đó các mô hình decoder-only (GPT-4o, Claude Haiku 4.5, Gemini 2.5 Flash) đóng vai trò tác nhân đề xuất và tổng hợp, còn PhoBERT (encoder-only) và ViT5 (encoder-decoder) phục vụ lần lượt cho tính toán BERTScore và phương án dự phòng định tuyến. Về mặt đánh giá, chương đã xây dựng hệ thống lý thuyết cho ba trục đo lường: Trục A với các hệ số overlap (ROUGE, BLEU, BERTScore), Trục B với phương pháp luận LLM-Judge (rubric theo FLASK, chấm điểm theo MT-Bench, so sánh cặp theo AlpacaEval, và đánh giá tính xác thực ở cấp mệnh đề), cùng Trục C với xếp hạng mù và hệ số Fleiss’ κ . Luận điểm lý thuyết then chốt nhất của chương — các hệ số overlap được tính so với bài báo gốc đo khả năng giữ lại nội dung chứ không đo chất lượng tóm tắt — chính là cơ sở lý luận cho việc thiết kế khung đánh giá đa trục thay vì phụ thuộc vào một trục duy nhất. Chương 3 sẽ trình bày cách các lý thuyết này được hiện thực hóa trong thiết kế và xây dựng hệ thống.

Chương 3

Thiết kế và xây dựng hệ thống

Chương này hiện thực hóa các nền tảng lý thuyết đã được trình bày trong Chương 2 thành một hệ thống phần mềm hoàn chỉnh mang tên Fiber — một tiện ích trình duyệt hỗ trợ tóm tắt tự động tin tức tiếng Việt. Nội dung chương được tổ chức theo trình tự từ phân tích yêu cầu đến đánh giá: Mục 3.1 phân tích các yêu cầu chức năng và phi chức năng; Mục 3.2 giới thiệu kiến trúc tổng quan hệ thống; Mục 3.3 trình bày module tóm tắt văn bản; Mục 3.4 mô tả pipeline dung hợp đa tác nhân MoA — đóng góp kỹ thuật cốt lõi của khóa luận; và Mục 3.5 chi tiết khung đánh giá ba trục — đóng góp chính về mặt phương pháp luận.

3.1 Phân tích yêu cầu hệ thống

3.1.1 Yêu cầu chức năng

Hệ thống được thiết kế với bảy yêu cầu chức năng chính:

- Tóm tắt văn bản: Nhận đầu vào là một đường dẫn tin tức tiếng Việt, trả về một bản tóm tắt tóm lược S sao cho $|S| \leq 0,5 \cdot |D|$ (độ dài bản tóm tắt không quá một nửa độ dài văn bản gốc).
- Truyền dữ liệu dạng luồng (Streaming): Truyền bản tóm tắt theo từng token qua kênh SSE (Server-Sent-Events) để đạt thời gian phản hồi dưới ba giây đối với token đầu tiên, tối ưu hóa trải nghiệm người dùng.
- Kiểm chứng thông tin: Theo yêu cầu của người dùng, phân tách bản tóm tắt thành các mệnh đề nhỏ, truy xuất các minh chứng trên web cho từng mệnh đề, và hiển thị điểm độ tin cậy cùng danh sách nguồn tham chiếu tương ứng.
- Chuyển đổi đa mô hình: Cho phép người dùng lựa chọn giữa các mô hình ngôn ngữ lớn được hỗ trợ tại thời điểm chạy; đồng thời lưu giữ lựa chọn cấu hình này qua các phiên làm việc.
- Hệ đo lường đánh giá: Sau mỗi lượt tóm tắt, tự động tính toán các chỉ số ROUGE-1/2/L, BLEU, BERTScore, tỷ lệ nén, các điểm số LLM-Judge, so sánh và ghi nhận kết quả vào cơ sở dữ liệu.
- Dung hợp đa tác nhân: Cung cấp chế độ định tuyến dung hợp, chạy song song ba tác nhân đề xuất và kết hợp kết quả thông qua một tác nhân tổng hợp.
- Quản trị đánh giá người dùng: Cho phép xây dựng các tác vụ xếp hạng ẩn danh K chiều với danh tính các mô hình bị ẩn và theo dõi các số liệu thống kê tổng hợp thuộc Trục C.

3.1.2 Yêu cầu phi chức năng


Hệ thống có khả năng đáp ứng bốn yêu cầu phi chức năng quan trọng:

- Độ trễ: Thời gian phản hồi token đầu tiên dưới 3 giây đối với tác vụ tóm tắt dạng luồng trên kết nối mạng băng thông rộng; hoàn thành toàn bộ bản tóm tắt dưới 10 giây đối với bài báo có độ dài ≤ 1000 từ.

- Khả năng mở rộng : Giao diện lập trình ứng dụng phía backend không lưu trạng thái và có khả năng mở rộng ngang thông qua Vercel; module BERTScore được triển khai dưới dạng một microservice độc lập trên Hugging Face Spaces.
- Bảo mật khóa API: Tất cả các khóa nhà cung cấp dịch vụ LLM đều được lưu trữ an toàn phía máy chủ; tiện ích mở rộng không bao giờ tiếp cận các khóa API này.
- Tương thích đa trình duyệt: Sử dụng chuẩn Manifest V3, được kiểm thử và xác thực hoạt động ổn định trên Google Chrome và Microsoft Edge.
- Theo dõi chi phí: Mỗi lượt gọi API tới LLM đều ghi lại chi phí thực tế theo đơn vị USD vào bảng số liệu đo lường để phục vụ mục đích kiểm soát ngân sách.

3.2 Kiến trúc tổng quan hệ thống

Kiến trúc của hệ thống Fiber bao gồm ba dịch vụ chính hoạt động phối hợp chặt chẽ (Hình 3.1). Tiện ích trình duyệt giao tiếp với backend Next.js thông qua các giao thức REST và SSE; backend chịu trách nhiệm tương tác với các nhà cung cấp LLM và microservice BERTScore; toàn bộ trạng thái dữ liệu được quản lý bởi cơ sở dữ liệu PostgreSQL trên nền tảng Supabase.



Hình 3.1: Kiến trúc hệ thống ba dịch vụ của Fiber.

3.3 Module tóm tắt văn bản

Module tóm tắt văn bản được thiết kế độc lập với mô hình và hoạt động ổn định trước nhiều độ dài đầu vào khác nhau. Quy trình tóm tắt tuân theo một luồng công việc hệ thống từ khâu trích xuất nội dung cho đến bước đánh giá.


3.3.1 Quy trình tóm tắt văn bản

Quy trình tóm tắt được điều phối nhịp nhàng thông qua cơ chế phân tách trách nhiệm rõ ràng giữa tiện ích trình duyệt phía client và API Next.js phía máy chủ. Như minh họa trong Hình 3.2, tác vụ tóm tắt có thể được kích hoạt qua hai cơ chế: (1) Thanh bên tự động, tự động nhận diện trang bài báo

khi tải để cung cấp bản tóm tắt toàn diện, và (2) Khung hội thoại kiểm chứng, trong đó người dùng bôi đen các phân đoạn văn bản cụ thể để kích hoạt một tooltip tóm tắt theo nhu cầu. Các yêu cầu này được gửi tới endpoint `/api/summarize` ở backend, nơi **Summarize Service** tương tác với LLM và xác thực kết quả đầu ra qua thư viện Zod trước khi gửi lại kết quả cho giao diện người dùng tiện ích mở rộng.

Quy trình tóm tắt từ đầu đến cuối gồm năm giai đoạn chính:

- Trích xuất: Khi trang web tải xong, tập kịch bản nội dung sử dụng thư viện Mozilla Readability để phân tích cú pháp DOM, loại bỏ các phần rác như quảng cáo, menu điều hướng để cô lập phần tiêu đề và nội dung chính của bài báo.
- Quyết định định tuyến: Hệ thống ước lượng số lượng token và kiểm tra chế độ định tuyến hiện hoạt của người dùng (Tự động - Auto, Bắt buộc - Forced, hoặc Dung hợp - Fusion). Điều này xác định nhà cung cấp dịch vụ LLM hoặc pipeline xử lý nào (ví dụ: MoA) sẽ được gọi.
- Kỹ thuật câu lệnh: Một câu lệnh gợi ý được cấu trúc động chứa văn bản gốc và các chỉ dẫn cụ thể cho tác vụ tóm tắt ý nghĩa bằng tiếng Việt được gửi tới mô hình đã chọn.
- Thực thi và truyền luồng: Mô hình tạo ra kết quả. Nếu chế độ truyền luồng được bật, các token được truyền trực tiếp qua kênh SSE để hiển thị thời gian thực trên giao diện. Ngược lại, toàn bộ văn bản tóm tắt sẽ được gửi về dưới dạng một khối hoàn chỉnh.
- Xác thực và hậu xử lý: Bản tóm tắt thô từ LLM được xác thực đối chiếu với một lược đồ Zod. Ngay sau khi phản hồi được gửi thành công cho người dùng, hệ thống sẽ kích hoạt một tác vụ đánh giá không đồng bộ ở chế độ nền để tính toán các chỉ số Trục A mà không gây nghẽn giao diện người dùng.




Hình 3.2: Nguyên lý hoạt động của dịch vụ tóm tắt văn bản.

3.4 Pipeline dung hợp đa tác nhân (MoA)

Pipeline MoA (Mixture-of-Agents) đại diện cho đóng góp kỹ thuật cốt lõi của khóa luận. Đây là một sự triển khai chính xác dựa trên công trình của Wang và các cộng sự [8] kết hợp với một cải tiến thiết kế quan trọng: nhúng bài viết gốc trực tiếp vào câu lệnh gợi ý của tác nhân tổng hợp. Cải tiến này là bắt buộc vì nhiệm vụ của hệ thống là tóm tắt dựa trên ngữ cảnh thực tế thay vì chỉ tuân thủ các chỉ dẫn tự do không ràng buộc.

3.4.1 Thiết kế hệ thống hai lớp

Lớp 1 (các tác nhân đề xuất) gồm ba mô hình: {gpt-4o-mini, claude-haiku-4.5, gemini-2.5-flash}. Mỗi tác nhân đề xuất nhận chung một câu lệnh đầu vào: “tóm tắt bài báo tiếng Việt này trong khoảng từ 5 đến 7 câu” và độc lập tạo ra bản thảo sơ bộ d_i ở chế độ song song. Lớp 2 là tác nhân tổng hợp sử dụng mô hình gpt-4o. Tác nhân này tiếp nhận đồng thời cả văn bản bài viết gốc D và danh sách các bản thảo sơ bộ $\{d_1, d_2, d_3\}$ để dung hợp và biên tập ra bản tóm tắt cuối cùng S^* (Hình 3.3).



Hình 3.3: Kiến trúc pipeline hai lớp MoA tích hợp kết nối phần dư.

3.4.2 Lớp đề xuất

Ba tác nhân đề xuất được tuyển chọn từ ba họ mô hình ngôn ngữ lớn thương mại đám mây khác nhau (OpenAI, Anthropic, Google) nhằm đảm bảo tính đa dạng trong tư duy ngôn ngữ của mô hình với chi phí vận hành cực kỳ tối ưu (cả ba đều thuộc phân khúc mô hình nhỏ gọn: *mini/haiku/flash* của các hãng). Cơ chế xử lý lỗi ngoại lệ: nếu bất kỳ một tác nhân đề xuất nào bị quá thời hạn phản hồi hoặc trả về lỗi API, quá trình dung hợp vẫn tiếp tục với các bản thảo còn lại; nếu hai hoặc cả ba tác nhân đề xuất đều gặp sự cố, hệ thống sẽ trả trực tiếp bản thảo sống sót duy nhất (nếu có) và ghi lại một cảnh báo lỗi vào tệp nhật ký hệ thống.

3.4.3 Lớp tổng hợp

Câu lệnh gợi ý cho tác nhân tổng hợp là cấu thành quan trọng nhất của hệ thống triển khai thực tế; nó quyết định việc tác nhân tổng hợp sẽ thực hiện biên dịch chi tiết hay chỉ đơn thuần chấp vấ cơ học các bản thảo lại với nhau. Trong kiến trúc hiện tại, mô hình `gpt-4o` được sử dụng làm tác nhân tổng hợp. Câu lệnh gợi ý, sau khi được tinh chỉnh vào ngày 08-05-2026 (thay đổi cuối cùng đem lại kết quả vượt trội), chỉ dẫn mô hình thực hiện:

- Đánh giá các bản thảo đề xuất một cách phản biện thay vì sao chép nguyên văn;
- Duy trì giọng văn báo chí tiếng Việt chuẩn mực, khách quan và trung lập;
- Đảm bảo bản tóm tắt hoàn toàn nhất quán với bài viết gốc;
- *Không* được sử dụng cụm từ “cô đọng” (tương đương với các chỉ dẫn “condense / concise”), cụm từ mà các kết quả thực nghiệm thực tế chỉ ra rằng thường hướng mô hình tới việc tạo ra các bản tóm tắt bị cắt cụt cục bộ và thiếu tính liên kết.

3.4.4 Kết nối phần dư bài viết gốc

Phương trình 1 của nghiên cứu gốc [8] chỉ thực hiện nối chuỗi câu lệnh gợi ý đầu vào với danh sách các bản thảo đề xuất. Đối với bài toán tóm tắt có ràng buộc thông tin thực tế, chỉ sử dụng câu lệnh gợi ý là không đủ — tác nhân tổng hợp cần bài viết gốc làm neo tham chiếu để xác thực và tổng hợp thông tin. Sự triển khai của công trình của khoá luận nhúng trực tiếp toàn văn bài viết gốc vào ngữ cảnh hệ thống của tác nhân tổng hợp như một nguồn đầu vào bổ sung song song với danh sách bản thảo.

Đường kết nối phần dư này mang lại hiệu quả thực nghiệm mang tính quyết định. Nếu không có bài viết gốc, tác nhân tổng hợp rơi vào trạng thái chấp vấ bản thảo (độ dài bản tóm tắt tăng $\approx 22\%$ so với độ dài bản thảo trung bình, chỉ số ROUGE-1 so với nguồn đạt $\approx 0,34$); khi có sự hiện diện của bài viết gốc, tác nhân tổng hợp chuyển sang trạng thái tổng hợp biên tập thực sự (độ dài ngắn hơn $\approx 17\%$, chỉ số ROUGE-1 giảm xuống còn $\approx 0,24$ do tính chất diễn đạt lại linh hoạt nhưng điểm đánh giá toàn diện Rubric tăng mạnh). Chi tiết các thực nghiệm cơ lập này được báo cáo tại Mục 4.2.

3.4.5 Thực nghiệm kỹ thuật câu lệnh đối với mô hình tổng hợp

Ba biến thể của câu lệnh gợi ý dành cho tác nhân tổng hợp đã được thử nghiệm trên tập dữ liệu gồm 50 bài báo từ trang *tienphong.vn*:

- Baseline — Câu lệnh trước khi tinh chỉnh; không đưa bài viết gốc vào ngữ cảnh của tác nhân tổng hợp.
- v1 - Strict source (Nguồn nghiêm ngặt) — Có đưa bài viết gốc vào ngữ cảnh, áp dụng quy tắc kiểm soát nghiêm ngặt “không được tự ý sáng tạo thông tin”.
- v2 - Soft source (Nguồn linh hoạt) — Có đưa bài viết gốc vào ngữ cảnh, sử dụng các diễn đạt linh hoạt hơn như “sử dụng bài viết như tài liệu tham chiếu tin cậy”.


Bảng đối chiếu chi tiết các phiên bản câu lệnh gợi ý này cùng các đoạn văn bản sửa đổi cụ thể được trình bày trong Phụ lục C.

Kết luận nổi bật nhất (được trình bày chi tiết tại Mục 4.2) chỉ ra rằng chỉ riêng sự xuất hiện của văn bản bài viết gốc trong ngữ cảnh tổng hợp đã làm thay đổi hoàn toàn hành vi của mô hình; trong khi các diễn đạt câu chữ chi tiết xung quanh quy tắc đó không tạo ra sự khác biệt quá lớn. Phiên bản câu

lệnh được tích hợp chính thức vào hệ thống là v2 cùng với việc loại bỏ từ khóa “cơ động” theo cập nhật vào ngày 08-05-2026.

3.5 Khung đánh giá ba trục


Mục này mô tả đóng góp về mặt phương pháp luận chính của khóa luận: một khung đánh giá tích hợp đồng thời ba khía cạnh độc lập bao gồm các số liệu đo lường khả năng giữ lại nội dung (Trục A), đánh giá chất lượng bằng LLM-Judge (Trục B) và xếp hạng của con người (Trục C). Quyết định xây dựng cấu trúc đánh giá ba trục xuất phát từ sau quan sát và phân tích: bất kỳ một trục đơn lẻ nào cũng tự bản thân nó mang những thiên kiến cấu trúc nội tại; chỉ khi kết hợp cả ba trục lại với nhau mới tạo ra một phương pháp định vị đa chiều đáng tin cậy để đo lường chất lượng hệ thống.



Hình 3.4: Khung đánh giá ba trục được sử dụng để định vị đa chiều chất lượng hệ thống.

3.5.1 Trục A — Khả năng giữ lại nội dung

Các số liệu thuộc Trục A được tính toán tự động ngay sau khi mỗi bản tóm tắt được tạo ra. Chỉ số ROUGE-1/2/L và BLEU được xử lý trực tiếp bằng các thư viện JavaScript `rouge` và `sacrebleu`. Chỉ số BERTScore được xử lý bởi microservice viết bằng Python. Cả bốn chỉ số đánh giá chất lượng này đều được tính toán đối chiếu trực tiếp với văn bản bài viết gốc, thay vì so sánh với bản tóm tắt mẫu do con người viết. Tỷ lệ nén được tính bằng công thức ký tự $|S|/|D|$.



Hình 3.5: Sơ đồ luồng tính toán các chỉ số thuộc Trục A (Khả năng giữ lại nội dung).


3.5.2 Trục B — Chất lượng và Mức độ ưu tiên

Trục B đóng vai trò là trục trọng tâm của khóa luận. Module `llm-judge.service.ts` cung cấp bốn hàm chức năng chính với khả năng đánh giá toàn diện chất lượng văn bản tóm tắt bằng LLM-Judge:

- `judgeRubric` — Bộ tiêu chuẩn đánh giá 5 chiều phát triển từ FLASK trên thang điểm từ 1–5.
- `judgeAbsolute` — Điểm số đánh giá toàn diện trên thang điểm 1–10 theo phong cách MT-Bench.
- `judgePairwise` — Đánh giá so sánh cặp A so với B tích hợp cơ chế ngẫu nhiên hóa vị trí.
- `scoreFactuality` (nằm trong `factuality.service.ts`) — Phân tích mệnh đề kết hợp phân loại chấp thuận.

Hai quy trình xử lý bậc cao hơn được vận hành riêng cho đầu ra của pipeline dung hợp MoA:

- `runFusionPairwiseJudge` — So sánh bản tóm tắt dung hợp với bản thảo tốt nhất của tác nhân đề xuất.
- `runFusionVsAllDraftsJudge` — So sánh bản tóm tắt dung hợp với từng bản thảo đề xuất đơn lẻ.
- Phép so sánh thứ ba, “dung hợp MoA so với bản tóm tắt chạy trực tiếp trên `gpt-4o` đơn lẻ” (`vs_single_aggregator`), được thực thi thông qua một script ngoại tuyến được mô tả tại Mục 4.3.4; đây là phép so sánh mang tính chất quyết định đối với toàn bộ khóa luận vì cả hai đối tượng so sánh đều là sản phẩm đầu ra của cùng một mô hình `gpt-4o`, nhờ đó triệt tiêu hoàn toàn thiên kiến thiên vị "cùng họ" của LLM-Judge.




Hình 3.6: Sơ đồ luồng xử lý đánh giá bằng LLM-Judge thuộc Trục B (Chất lượng và Mức độ ưu tiên).

3.5.3 Trục C — Đánh giá bởi con người

Trục C sử dụng chính giao diện web của hệ thống để tổ chức các tác vụ xếp hạng mà dành cho người đánh giá.

- Người thực hiện nghiên cứu tạo một tác vụ đánh giá tại đường dẫn quản trị `/evaluate/admin`. Mỗi tác vụ tương ứng với một bài báo gốc và ba bản tóm tắt ứng viên (bản dịch dung hợp MoA, bản tóm tắt GPT-4o đơn lẻ, và bản thảo GPT-4o-mini) với danh tính mô hình đã được ẩn giấu hoàn toàn. Các ứng viên được gán nhãn trung lập là *Bản A*, *Bản B*, *Bản C*.
- Người đánh giá truy cập đường dẫn `/evaluate?task=<uuid>`, nhập mã nhận diện định danh duy nhất (rater code), thực hiện thao tác kéo thả để xếp hạng vị trí của ba ứng viên, và viết một câu nhận xét ngắn bằng tiếng Việt giải thích lý do lựa chọn cho mỗi bản tóm tắt.
- Các phản hồi được ghi nhận vào bảng cơ sở dữ liệu `human_eval_responses`; một chỉ mục duy nhất một phần được thiết lập trên tổ hợp trường (`task_id`, `rater_id`) để ngăn chặn hành vi gửi phản hồi hai lần của cùng một người đánh giá trên một tác vụ.
- API `/api/human-eval/report` chịu trách nhiệm tính toán tổng hợp thứ hạng trung bình của từng mô hình, tỷ lệ thắng tương ứng, và hệ số độ đồng thuận Fleiss' κ .



Hình 3.7: Sơ đồ luồng xử lý và tổng hợp số liệu thống kê thuộc Trục C (Đánh giá của con người).

3.5.4 Phân tích thống kê

Để đảm bảo các kết quả thực nghiệm thu được đạt độ tin cậy khoa học cao nhất, hệ thống tích hợp một thư viện xử lý thống kê chuyên biệt (`backend/output-fusion/scripts/stats.ts`). Quá trình triển khai tập trung xử lý bốn nhóm tác vụ cốt lõi nhằm đảm bảo các số liệu đo lường được báo cáo trong các chương tiếp theo đạt tính chính xác và khả năng tái lập cao:

- **Kiểm định ý nghĩa thống kê (Trục A/B):** Hệ thống sử dụng phương pháp tính giá trị p-value nhị thức hai chiều chính xác thông qua hàm `signTestPValue`. Để xử lý các bài toán có kích thước mẫu thực nghiệm lớn mà không gây lỗi tràn số bộ nhớ, một bộ đệm lưu log-giai thừa được thiết kế để thực hiện toàn bộ phép tính trong không gian logarit, giúp triệt tiêu hoàn toàn hiện tượng tràn số dấu phẩy động thường gặp khi tính toán các tổ hợp lớn $C(n, k)$.
- **Hiệu chỉnh thiên kiến độ dài (Trục B):** Do các mô hình ngôn ngữ lớn làm giảm khảo thường có xu hướng ưu tiên các văn bản đầu ra có độ dài lớn hơn [1], hệ thống đã triển khai giải thuật `length BucketedWinRate`. Bằng cách phân chia các phán quyết vào ba nhóm dựa trên tỷ lệ độ dài tương

ứng L_A/L_B (< 0.85 , $0.85-1.15$, và > 1.15), hệ thống có thể tính toán một tỷ lệ thắng cân bằng và khách quan hơn, không còn bị chi phối bởi độ dài văn bản.

- Độ đồng thuận giữa các người đánh giá (Trục C): Để đo lường mức độ thống nhất trong các quyết định xếp hạng của những người đánh giá con người độc lập, hệ thống tính toán hệ số Fleiss' κ thông qua hàm `fleissKappaFromRankings`. Khoá luận áp dụng bộ khung diễn giải tiêu chuẩn của Landis và Koch [2] để đánh giá các chỉ số này, hướng tới việc đạt hệ số đồng thuận ở mức ít nhất là "trung bình" ($\kappa > 0.4$) để đảm bảo nghiên cứu khảo sát đạt độ giá trị khoa học cần thiết.
- Tổng hợp số liệu cặp: Đối với các chỉ số đo lường khả năng giữ lại nội dung ở Trục A, hàm `pairedMetricStats` chịu trách nhiệm tự động tính toán giá trị trung bình, độ lệch chuẩn và sai lệch cặp thực nghiệm. Giải thuật được thiết kế để tự động loại bỏ các dữ liệu khuyết thiếu (missing data) và tính toán p-value kiểm định dấu (sign-test) cho các phép so sánh đối đầu trực tiếp, cung cấp một phương thức chuẩn hóa để báo cáo số liệu trên toàn bộ Trục A.

3.6 Tổng kết chương

Chương này đã trình bày quá trình thiết kế và xây dựng hệ thống Fiber. Về mặt kiến trúc, hệ thống bao gồm tiện ích trình duyệt Plasmo chịu trách nhiệm trích xuất nội dung và hiển thị, cùng backend Next.js 14 đóng vai trò điều phối trung tâm. Về mặt kỹ thuật, pipeline MoA hai lớp với ba tác nhân đề xuất đa nhà cung cấp và một tác nhân tổng hợp GPT-4o đã được triển khai trên cơ sở nghiên cứu gốc của Wang et al. [8], kết hợp với cải tiến quan trọng là nhúng trực tiếp bài viết gốc vào ngữ cảnh tổng hợp thông qua kết nối phần dư — biến tác nhân tổng hợp từ chế độ chấp vá bản thảo sang chế độ tổng hợp biên tập thực sự. Về mặt phương pháp luận, khung đánh giá ba trục tích hợp đồng thời các hệ số overlap tự động (Trục A), đánh giá chất lượng bằng LLM-Judge (Trục B) và xếp hạng mù bởi con người (Trục C), đảm bảo rằng mọi kết luận khoa học đều được kiểm chứng từ ba góc nhìn độc lập. Toàn bộ thiết kế này sẽ được kiểm chứng thực nghiệm trên tập dữ liệu 154 bài báo tiếng Việt trong Chương 4.

Chương 4

Thực nghiệm và đánh giá

Chương này kiểm chứng thực nghiệm hệ thống Fiber đã được xây dựng trong Chương 3 thông qua khung đánh giá ba trục trên tập dữ liệu gồm 154 bài báo tiếng Việt cân bằng theo năm nhóm chủ đề. Mục 4.1 trình bày thiết lập thực nghiệm bao gồm tập dữ liệu, các mô hình so sánh và hệ đo lường; Mục 4.2 báo cáo kết quả Trục A về khả năng giữ lại nội dung; Mục 4.3 trình bày kết quả Trục B về chất lượng và mức độ ưu tiên, bao gồm phép so sánh mang tính quyết định giữa bản dung hợp MoA và GPT-4o đơn lẻ; Mục 4.4 phân tích kết quả Trục C từ khảo sát 17 người đánh giá độc lập; Mục 4.5 thực hiện phân tích đa trục để đối chiếu và tam giác hóa các kết quả; và Mục 4.6 thảo luận về các hạn chế phương pháp luận.

4.1 Thiết lập thực nghiệm

4.1.1 Tập dữ liệu

Quá trình đánh giá hiệu năng của các mô hình được thực hiện trên tập dữ liệu gồm 154 bài báo tiếng Việt, được thu thập trực tiếp từ báo điện tử *tienphong.vn*. Để đảm bảo tính toàn diện và khách quan, tập dữ liệu được thiết kế cân bằng cấu trúc theo chủ đề với tỷ lệ phân bổ xấp xỉ 30 bài mỗi nhóm, trải dài trên năm danh mục nội dung cốt lõi bao gồm: *Thời sự*, *Pháp luật*, *Kinh tế*, *Giáo dục* và *Văn hóa*.

Việc thiết kế một tập dữ liệu cân bằng theo phân vùng chủ đề (được chi tiết hóa trong Bảng 4.1) đóng vai trò quan trọng trong việc kiểm soát các biến nhiễu do phong cách viết đặc thù, thuật ngữ chuyên ngành hoặc độ dài trung bình của từng thể loại báo chí. Đồng thời, cấu trúc này thiết lập cơ sở dữ liệu nền tảng phục vụ cho các phân tích sâu về sự tương tác và biến thiên hiệu năng của mô hình theo từng nhóm chủ đề được trình bày chi tiết tại Mục 4.4.3.

Bảng 4.1: Phân bố số lượng bài báo trong tập dữ liệu thực nghiệm theo danh mục

Chủ đề	Số lượng bài báo	Đặc trưng nội dung
Thời sự	31	Tin tức chính trị, xã hội, sự kiện nóng.
Pháp luật	31	Văn bản pháp quy, án lệ, an ninh trật tự.
Kinh tế	30	Tài chính, thị trường, kinh doanh vĩ mô.
Giáo dục	31	Tuyển sinh, chính sách giáo dục, học đường.
Văn hóa	31	Nghệ thuật, đời sống, giá trị truyền thống.
Tổng cộng	154	

4.1.2 Các mô hình so sánh

Năm mô hình xử lý tóm tắt văn bản được đưa vào đánh giá và so sánh trên từng bài báo:

- MoA FUSION — gồm ba mô hình GPT-4o-mini, Claude Haiku 4.5, Gemini 2.5 Flash là tác nhân đề xuất kết hợp với tác nhân tổng hợp GPT-4o.
- GPT-4o — mô hình cơ sở mạnh nhất, sử dụng mô hình `gpt-4o-2024-08-06`. Phương án này được sử dụng trong phép so sánh mang tính quyết định của khóa luận.
- Claude Haiku 4.5 — mô hình cơ sở thuộc phân cấp tác nhân đề xuất (nhà cung cấp Anthropic).

- Gemini 2.5 Flash — mô hình cơ sở thuộc phân cấp tác nhân đề xuất (nhà cung cấp Google).
- GPT-4o-mini — mô hình cơ sở thuộc phân cấp tác nhân đề xuất (nhà cung cấp OpenAI).

4.1.3 Các hệ đo lường

- Trục A (khả năng giữ lại nội dung): Bao gồm các hệ số ROUGE-1, ROUGE-L, BLEU, BERTScore (với mô hình nền PhoBERT) và tỷ lệ nén. Các hệ số này được tính toán so với bài viết nguồn.
- Trục B (chất lượng và mức độ ưu tiên): Bao gồm điểm số đánh giá theo thang điểm 1–5, tỷ lệ thắng đấu cặp kèm theo giá trị p của kiểm định dấu và kiểm soát phân nhóm theo độ dài, tỷ lệ chấp thuận logic phục vụ xác định tính xác thực. Mô hình LLM-Judge được sử dụng là `gpt-4o-mini-2024-07-18`.
- Trục C (đánh giá của con người): Phương pháp xếp hạng mù $K = 3$; tính toán thứ hạng trung bình của từng phương án, tỷ lệ xếp hạng nhất, tỷ lệ thắng đấu cặp, và đo lường độ đồng thuận giữa các người đánh giá.

4.2 Kết quả Trục A — Khả năng giữ lại nội dung

Kết quả thực nghiệm đo được của trục A được biểu thị trong bảng 4.2 cho thấy báo cáo các hệ số overlap từ vịnh được tính trung bình trên 154 lượt chạy dung hợp và các lượt chạy mô hình đơn lẻ tương đương làm cơ sở đối chiếu.

Bảng 4.2: Trục A — các hệ số overlap so với bài viết nguồn (điểm số càng cao thể hiện bản tóm tắt càng bám sát văn phong từ vịnh của bài gốc).

Mô hình	n	ROUGE-1	ROUGE-L	BLEU	BERTScore	Tỷ lệ nén%
MoA FUSION	154	0,4240	0,3300	0,1349	0,6759	42,6
gemini-2.5-flash	100	0,3503	0,2677	0,0894	0,6538	33,7
claude-haiku-4.5	100	0,3502	0,2830	0,0871	0,6487	34,7
gpt-4o	50	0,3621	0,2567	0,0688	0,6246	37,6
gpt-4o-mini	100	0,2454	0,1849	0,0290	0,6217	24,9

Mô hình kết hợp MoA FUSION chiến thắng trên tất cả các hệ số đo lường mức độ giữ lại nội dung — đạt điểm ROUGE-1 0,4240 so với 0,3621 của GPT-4o đơn lẻ, và BERTScore 0,6759 so với 0,6246. Điều này *trái ngược* với những dự đoán từ nghiên cứu thử nghiệm ban đầu của khóa luận (khi đó khoá luận giả định rằng kết quả dung hợp MoA sẽ có điểm overlap thấp hơn do cơ chế tổng hợp kiểu biên tập sẽ diễn giải lại thông tin một cách mạnh mẽ hơn).

Dự đoán trong giai đoạn thử nghiệm ban đầu được đưa ra dựa trên một câu lệnh tổng hợp nguồn nghiêm ngặt (được thử nghiệm trước 08-05-2026). Dưới tác động của câu lệnh ràng buộc nghiêm ngặt đó, mô hình tổng hợp đã thu gọn các bản thảo thành một đoạn văn biên tập rất ngắn, trực tiếp kéo điểm overlap đi xuống. Sau khi tối ưu hóa câu lệnh tổng hợp, mô hình tổng hợp giờ đây vừa giữ lại được khung lập luận trung thực với bài gốc, vừa diễn giải các dữ kiện chính bằng các cụm từ rất sát với nguồn, khiến điểm overlap tăng vượt trội hơn bất kỳ bản thảo đơn lẻ nào.

Kết quả sau khi tối ưu hóa câu lệnh mang ý nghĩa thực tiễn quan trọng: ngay cả trên Trục A, phương pháp dung hợp vẫn cho thấy hiệu quả tương đương hoặc vượt trội so với mô hình đơn lẻ mạnh nhất. Hệ đo lường trùng lặp so với bài gốc không còn là một điểm yếu; trái lại, nó trở thành trục thứ ba đồng thuận chặt chẽ với Trục B và Trục C, giúp củng cố vững chắc hơn luận điểm khoa học ủng hộ phương pháp dung hợp đa tác nhân.

4.3 Kết quả Trục B — Chất lượng và sự ưu tiên

4.3.1 Đánh giá theo Rubric (FLASK cải tiến, 1–5)

Bảng 4.3 báo cáo điểm số rubric trung bình theo từng chiều đánh giá trên 154 lượt chạy dung hợp và các lượt chạy mô hình đơn lẻ tương ứng.

Bảng 4.3: Trục B.1 — điểm số rubric đánh giá bằng LLM-giám khảo (1–5). Sử dụng `judge_model = gpt-4o-mini-2024-07-18`.

Mô hình	<i>n</i>	Faithfulness	Coverage	Fluency	Conciseness	Overall
MoA FUSION	154	5,00	4,94	4,98	4,88	4,96
claude-haiku-4.5	100	5,00	4,78	4,97	4,92	4,91
gpt-4o	50	5,00	4,78	4,98	4,84	4,88
gemini-2.5-flash	100	4,96	4,76	5,00	4,95	4,86
gpt-4o-mini	100	4,98	4,34	4,97	4,84	4,61

Mô hình kết hợp MoA FUSION vượt trội hơn mọi mô hình cơ sở ở điểm số đánh giá Tổng thể toàn diện (4,96 so với 4,91 của mô hình đứng sau). Yếu tố đóng góp khác biệt lớn nhất là tiêu chí Độ bao phủ (Coverage) (4,94 so với 4,78 của GPT-4o đơn lẻ, tạo ra khoảng cách +0,16); kết quả này hoàn toàn nhất quán với cơ chế “hợp các bản thảo”. Điểm số tiêu chí Tính trung thực (Faithfulness) gần như bão hòa đối với tất cả các phương pháp ($\geq 4,96$), phản ánh rằng mô hình kết hợp và các mô hình ứng viên đều là những mô hình mạnh mẽ, và hiện tượng mâu thuẫn logic trực tiếp là rất hiếm gặp.

4.3.2 Kết quả dung hợp so với Bản thảo đơn lẻ tốt nhất

Đây là phép so sánh đối chiếu đầu cặp chính trên toàn bộ tập dữ liệu gồm 154 bài báo. Mô hình LLM-Judge sẽ đánh giá bản tóm tắt dung hợp MoA đối đầu với bản thảo đề xuất đơn lẻ mạnh nhất ứng với từng bài báo.

Bảng 4.4: Trục B.2a — phán quyết đầu cặp, bản dung hợp (A) đấu với bản thảo tốt nhất (B) trên toàn bộ tập dữ liệu. Các kết quả hòa được tính vào tổng số lượng.

<i>n</i>	Bản dung hợp thắng	Bản thảo tốt nhất thắng	Hòa	Tỷ lệ thắng dung hợp (không tính hòa)
153	93	42	18	68,9%

Trong số 153 phán quyết phân định rõ ràng, bản tóm tắt dung hợp giành chiến thắng 93 lần, bản thảo đơn lẻ tốt nhất thắng 42 lần, và có 18 trường hợp hòa. Nếu loại trừ các trường hợp hòa, bản tóm tắt dung hợp được ưa thích hơn bản thảo tốt nhất trong gần 69% các lượt so sánh trực tiếp (chiếm 60,8% tổng số lượt so sánh). Mẫu thử nghiệm quy mô lớn này xác nhận rằng việc cung cấp nhiều bản thảo làm ngữ cảnh cho mô hình tổng hợp giúp tạo ra bản tóm tắt chất lượng vượt trội hơn hẳn so với việc chỉ sử dụng một mô hình đề xuất đơn lẻ.

4.3.3 Kết quả dung hợp so với từng mô hình đề xuất

Nhằm đối chiếu trực tiếp với kết quả nghiên cứu của Wang et al. [8] (Hình 4a), Bảng 4.5 báo cáo tỷ lệ chiến thắng của phương pháp dung hợp khi đối đầu với từng mô hình đề xuất riêng lẻ.

Bảng 4.5: Trục B.2b — bản dung hợp đấu với từng mô hình đề xuất. Kiểm định dấu (sign-test) được thực hiện hai chiều; loại trừ các trường hợp hòa.

Mô hình đề xuất	n	Dung hợp thắng	Bản thảo thắng	Hòa	Tỷ lệ thắng dung hợp	Giá trị p Sign-test
gpt-4o-mini	50	49	1	0	98,0%	0,0000
claude-haiku-4.5	50	41	8	1	83,7%	0,0000
gemini-2.5-flash	50	32	14	4	69,6%	0,0114

Tỷ lệ chiến thắng thô của bản dung hợp lần lượt là 98,0%, 83,7%, 69,6%; sau khi áp dụng kiểm soát phân nhóm theo độ dài (length-bucketed), tỷ lệ này đạt 97,9%, 84,3%, 72,0%. Điểm số phân nhóm biến động rất nhỏ (trong khoảng $\pm 2,4$ điểm phần trăm so với tỷ lệ thô), xác nhận rằng thiên kiến độ dài của LLM-Judge không phải là yếu tố ảnh hưởng kết quả này.

Bản tóm tắt dung hợp vượt qua từng mô hình đề xuất riêng lẻ với ý nghĩa thống kê rõ rệt. Khoảng cách này lớn nhất khi đối đầu với mô hình yếu nhất (GPT-4o-mini, 98%) và thu hẹp nhất khi gặp mô hình mạnh nhất (Gemini 2.5 Flash, 70%). Hiện tượng này hoàn toàn khớp với đặc tính kỹ thuật được công bố trong nghiên cứu MoA gốc [8]: cơ chế dung hợp tạo ra chênh lệch lớn nhất khi các mô hình đề xuất có năng lực hạn chế hơn, và sự hiện diện của một mô hình đề xuất mạnh sẽ thu hẹp nhưng không thể xóa bỏ khoảng cách năng lực này.

4.3.4 Kết quả dung hợp so với GPT-4o

Đây là phép so sánh đối chiếu có kiểm soát mô hình mang tính quyết định nhất trong khóa luận này. Bằng cách cố định mô hình tạo ra kết quả cuối cùng (cả hai bản tóm tắt đối đầu đều là kết quả đầu ra của GPT-4o), khóa luận đã có thể cô lập hoàn toàn tác động của quy trình dung hợp (cung cấp ba bản thảo đề xuất làm ngữ cảnh đầu vào cho mô hình tổng hợp) khỏi tác động của năng lực bản thân mô hình.

Bảng 4.6: Trục B.2c — phán quyết đấu cặp, bản dung hợp (A) so sánh với GPT-4o chạy đơn lẻ (B). Kiểm định dấu thực hiện hai chiều; loại trừ các trường hợp hòa.

n	Dung hợp thắng	Đơn lẻ thắng	Hòa	Tỷ lệ thắng dung hợp	Giá trị p Sign-test
48	37	11	0	77,1%	0,0002

Trong số 48 kết quả so sánh phân định rõ ràng, bản dung hợp giành chiến thắng 37 lần, mô hình GPT-4o chạy đơn lẻ thắng 11 lần, không ghi nhận trường hợp hòa nào. Dưới giả thuyết không $H_0 : P(\text{dung hợp thắng}) = 0,5$, xác suất xuất hiện từ 37 chiến thắng trở lên trong tổng số 48 trận đấu là $p = 0,0002$ (tương đương tỷ lệ 1 trên 5.000). Kết quả cho thấy sự vượt trội mà dung hợp mang lại.

4.3.5 Ảo giác mô hình và tính xác thực của kết quả

Bảng 4.7 báo cáo số liệu thống kê về tỷ lệ chấp thuận logic ở cấp độ mệnh đề trên cả năm phương án đánh giá. Kết quả dung hợp đạt tỷ lệ chấp thuận là 94,4%, minh chứng rằng quy trình dung hợp bảo toàn tốt tính trung thực của dữ kiện trong khi vẫn thực hiện tổng hợp thông tin từ nhiều bản thảo đề xuất khác nhau.

Bảng 4.7: Trục B.3 — đánh giá tính xác thực qua quan hệ kéo theo cấp mệnh đề (sử dụng mô hình phán quyết `gpt-4o-mini`).

Mô hình	n	tỷ lệ chấp thuận %	Ảo giác TB	Trường hợp xấu nhất
MoA FUSION	154	94,4	-	-
claude-haiku-4.5	100	95,5	0,07	1
gemini-2.5-flash	100	94,7	0,10	2
gpt-4o-mini	100	92,8	0,08	2
gpt-4o	50	89,9	0,08	1

Trên toàn bộ cơ sở dữ liệu gồm 923 mệnh đề được đánh giá, tỷ lệ chấp thuận tổng hợp đạt 94,4%. Tỷ lệ chấp thuận thấp nhất ghi nhận ở mô hình GPT-4o đơn lẻ (89,9%). Kết quả này củng cố quan sát thực tế rằng khi hoạt động độc lập không có bước “kiểm duyệt biên tập” mà pipeline MoA cung cấp một cách gián tiếp, GPT-4o có xu hướng vận hành ở chế độ sáng tạo hơn và đôi khi đưa vào những dữ kiện không được văn bản gốc hỗ trợ trực tiếp, hay còn gọi là ảo giác.

4.4 Kết quả Trục C — Đánh giá của con người

4.4.1 Thiết lập khảo sát

Một khảo sát đã được triển khai với sự tham gia của 17 người đánh giá độc lập, bao phủ toàn bộ 48 tác vụ thực nghiệm, thu về tổng cộng 192 kết quả xếp hạng mù $K = 3$. Mỗi tác vụ hiển thị đồng thời ba ứng viên tóm tắt — bản dung hợp MoA, bản GPT-4o đơn lẻ, và bản thảo đề xuất GPT-4o-mini — dưới các nhãn ngẫu nhiên *Bản A*, *Bản B*, *Bản C* nhằm ẩn hoàn toàn danh tính của mô hình.

4.4.2 Kết quả nổi bật trên Trục C

Bảng 4.8: Trục C — các chỉ số thống kê mô tả tổng hợp từ người đánh giá, quy mô $n = 192$ kết quả xếp hạng trên 48 tác vụ.

Mô hình	Hạng trung bình (↓)	Tỷ lệ xếp hạng nhất	Tỷ lệ đối đầu vs. Dung hợp
MoA FUSION	1,95	40,9%	—
gpt-4o	2,00	32,3%	Dung hợp thắng 40,9%
gpt-4o-mini	2,05	26,8%	Dung hợp thắng 40,9%

Bản tóm tắt của MoA FUSION là phương án được người đọc ưa thích nhất trên tất cả các tiêu chí đo lường tổng hợp: thứ hạng trung bình thấp nhất, tỷ lệ xếp hạng nhất cao nhất và ưu thế chiến thắng trong các cặp đối đầu so sánh trực diện. Tuy nhiên, khoảng cách vượt trội này nhỏ hơn rất nhiều so với những gì Trục B thể hiện. LLM-Judge báo cáo tỷ lệ thắng lên tới 68,9% trong các phán quyết so sánh quyết định (dung hợp đối đầu bản thảo tốt nhất); trong khi kết quả so sánh của con người chỉ báo cáo mức độ ưa thích 40,9% dành cho bản dung hợp. Khoảng cách chênh lệch này đã được nghiên cứu, tiếp tục thảo luận và lý giải ở các mục tiếp theo.

4.4.3 Tương tác theo nhóm chủ đề

Bảng 4.9 trình bày kết quả phân tích chi tiết theo từng nhóm chủ đề. Để phục vụ phân tích sâu, năm chủ đề báo chí của *tienphong.vn* được gom lại thành ba nhóm thể loại dựa trên nhận định trực quan của người đọc: nhóm chủ đề HÀNH CHÍNH (chính trị, hành chính, công văn nghị quyết; gồm 21 bài), nhóm chủ đề GIẢI TRÍ (lễ hội, người nổi tiếng, giải trí; gồm 13 bài), và nhóm chủ đề HỖN HỢP (hình sự, tin quốc tế, quan điểm độc giả; gồm 14 bài).

Bảng 4.9: Trục C — sở thích xếp hạng phân nhánh theo nhóm chủ đề. Ký hiệu: F = Bản dung hợp, $4o$ = GPT-4o đơn lẻ, m = Bản thảo gpt-4o-mini.

Nhóm chủ đề	n	Tỷ lệ F hạng nhất	Tỷ lệ $4o$ hạng nhất	Tỷ lệ m hạng nhất	$F > 4o$	$F > m$
HÀNH CHÍNH	84	23%	37%	41%	36%	43%
GIẢI TRÍ	52	58%	21%	21%	65%	65%
HỖN HỢP	56	59%	29%	13%	70%	77%

Trên nhóm nội dung mang tính hành chính (đại hội Đảng, báo cáo hành chính, hội nghị ban ngành), người đọc có xu hướng ưa thích bản tóm tắt ngắn nhất (bản thảo tạo bởi GPT-4o-mini) — vốn chính là ứng viên bị LLM-Judge xếp cuối cùng về tiêu chí Độ bao phủ (Coverage) trong Mục 4.3.1. Bản tóm tắt dung hợp — một văn bản dài hơn, được tổng hợp biên tập chi tiết — bị người đọc đánh giá thấp hơn; do thiếu đi sự hứng thú tự thân với chủ đề. Ngược lại, đối với thể loại giải trí và các chủ đề hỗn hợp, bản tóm tắt dung hợp đầy đủ thông tin hơn lại được ưa thích vượt trội (đạt tỷ lệ xếp hạng nhất lần lượt là 58% và 59%), hoàn toàn đồng điệu với nhận định của LLM-Judge.

LLM-Judge hoàn toàn không có khả năng nhận biết mức độ hấp dẫn của chủ đề đối với người đọc thực tế; nó chỉ chấm điểm máy móc theo rubric định sẵn và luôn thưởng điểm cho Độ bao phủ một cách đồng nhất. Trong khi đó, con người mang theo mục đích đọc thực tế khi tiếp cận bài viết, và mục đích này sẽ triệt tiêu tiêu chí Độ bao phủ khi họ gặp các chủ đề tẻ nhạt. Đây chính là phát hiện về mặt phương pháp luận mà khung đánh giá ba trục được thiết kế để chỉ ra.

4.4.4 Độ đồng thuận giữa các người đánh giá

Tính trung bình trên 48 tác vụ, số lượng người đánh giá đồng thuận lớn nhất về vị trí hạng nhất (#1) đạt 2,69 trên 4 người ($\approx 67\%$). Có 8 tác vụ đạt sự đồng thuận tuyệt đối (4/4), 17 tác vụ ghi nhận sự đồng thuận của 3 trên 4 người, 23 tác vụ bị chia rẽ nửa này nửa kia (2 vs. 2), và hoàn toàn không có tác vụ nào có ý kiến bị phân mảnh hoàn toàn. Kết quả này tương ứng với hệ số Fleiss' κ ước tính nằm trong khoảng đồng thuận vừa phải ($\approx 0,30\text{--}0,40$); mức độ đồng thuận thấp nhất ở nhóm chủ đề HÀNH CHÍNH (trung bình chỉ 2,48 người đồng ý với nhau) và cao nhất ở nhóm GIẢI TRÍ (2,92 người). Chỉ số này phản ánh chính xác hành vi của độc giả trong thực tế — họ chia sẻ một số sở thích chung cốt lõi, nhưng cũng có những bất đồng sâu sắc khi đánh giá các nội dung hành chính khô khan.

4.5 Phân tích đa trục

Góc nhìn khoa học quan trọng nhất từ các thực nghiệm chính là việc đối chiếu đồng thời cả ba trục đánh giá. Bảng 4.10 đối chiếu phép so sánh then chốt giữa bản dung hợp MoA và GPT-4o chạy đơn lẻ trên từng trục.

Bảng 4.10: Đối chiếu đa trực, bản dung hợp đối đầu với các mô hình cơ sở.

Trực	Chỉ số đo lường	Kết quả phán quyết
A	ROUGE-1 (0,4240 đầu với 0,3621)	Dung hợp dẫn +0,062
A	BERTScore (0,6759 đầu với 0,6246)	Dung hợp dẫn +0,051
B.1	Điểm Tổng thể Rubric (4,96 đầu với 4,88)	Dung hợp dẫn +0,08
B.2a	Tỷ lệ thắng đầu cặp so với bản thảo tốt nhất (68,9%)	Dung hợp thắng vượt trội
C	Kết quả so sánh của con người (40,9% đa số tương đối)	Dung hợp thắng với chênh lệch thấp

Cả ba góc nhìn độc lập đều thống nhất rằng phương pháp dung hợp MoA mang lại kết quả tốt hơn. Sự đồng thuận về mặt chiều hướng này là kết quả lý tưởng nhất của khung đánh giá ba trực.

Biên độ vượt trội của phương pháp dung hợp biến động rất lớn tùy theo hệ số đo lường: tăng nhẹ +0,05 đến +0,06 trên Trực A, dẫn +0,08 trên Trực B.1, thắng áp đảo với cách biệt +18,9 điểm phần trăm trên Trực B.2a (vượt mức 50%), nhưng lại thắng với chênh lệch nhỏ trên Trực C (40,9% chưa đạt mức đa số tuyệt đối, dù vẫn chiếm đa số tương đối). Khoảng chênh lệch 28 điểm phần trăm giữa Trực B.2a (68,9%) và Trực C (40,9%) là số liệu đáng giá nhất trong khóa luận này: **Sự ưu tiên của LLM-Judge, trong thiết lập thực nghiệm này, không phản ánh đúng biên độ ưa thích của con người thực tế.** Chiều hướng đánh giá là chính xác, nhưng biên độ đã bị phóng đại quá mức.

Khoảng chênh lệch này có thể được giải thích bằng các giả thuyết thu thập được sau quá trình phỏng vấn người đánh giá:

- Thiên kiến ủng hộ độ dài và tính toàn diện: LLM-Judge luôn cộng điểm cho Độ bao phủ (Coverage) một cách nhất quán; bản tóm tắt dung hợp dài hơn và bao hàm nhiều thông tin hơn bản GPT-4o đơn lẻ, nên LLM-Judge dễ dàng phán quyết. Con người, khi đối diện với các chủ đề hành chính khô khan, lại phản ứng ngược lại.
- Tương tác theo nhóm chủ đề: LLM-Judge không có nhận thức về sở thích và hành vi đọc; con người thì có (Mục 4.4.3).
- Hiệu ứng phân cực phán quyết: Các LLM-Judge khi so sánh thường nhạy cảm với các khác biệt nhỏ và có xu hướng phóng đại khoảng cách này [11]; trong khi con người thực tế đánh giá một cách dè dặt và có xu hướng nghiêng về kết quả hòa nhiều hơn.

Việc chỉ sử dụng một trực đánh giá duy nhất là không đủ để báo cáo đầy đủ về hiệu năng của phương pháp MoA. Kết quả từ cả ba trực cần được kết hợp chặt chẽ để bổ trợ lẫn nhau; nếu chỉ chạy riêng Trực B, khóa luận sẽ vội vã kết luận tỷ lệ thắng áp đảo lên tới 77% trong khi thực tế kết quả ghi nhận từ con người (Trực C) chỉ dừng lại ở mức 41%.

4.6 Hạn chế phương pháp luận

Sau quá trình thực nghiệm và đánh giá toàn diện, có một số hạn chế phương pháp luận có thể ghi nhận như sau:

- Kiến trúc đơn giản hoá: Cấu hình MoA được triển khai thực tế trong hệ thống này là cấu hình tối thiểu mà nghiên cứu gốc xem xét: chỉ gồm hai tầng gồm ba mô hình đề xuất kết hợp một mô hình tổng hợp. Bảng 3 và 4 trong công trình của Wang et al. [8] chỉ ra rằng hiệu năng của hệ thống

tăng đơn điệu theo độ sâu của tầng tác nhân ($\ell \in \{1, 2, 3\}$) và số lượng mô hình đề xuất trong mỗi tầng ($n \in \{3, 4, 5, 6\}$). Thiết kế hiện tại được lựa chọn để tối ưu hóa chi phí và kiểm soát độ trễ thời gian thực; việc nâng cấp chiều sâu và chiều rộng của mạng lưới tác nhân là những hướng phát triển tiềm năng cho các công trình tương lai.

- Quy mô nghiên cứu con người và động lực của người đánh giá: Nghiên cứu con người hiện tại có sự tham gia của 17 người đánh giá độc lập, cung cấp một cơ sở định tính rất giá trị. Tuy nhiên, việc phụ thuộc vào nhóm người đánh giá thực tế này cũng đặt ra một số thách thức đặc thù. Thứ nhất là vấn đề sở thích chủ đề cá nhân; khi đối mặt với các bài báo, những người đánh giá ngẫu nhiên có thể thể hiện mức độ tập trung nhận thức rất khác nhau tùy thuộc vào mức độ quan tâm của họ đối với nội dung bài viết. Sự thiên lệch về hứng thú này có thể đưa thêm các yếu tố nhiễu vào số liệu thống kê sở thích chung. Thứ hai, nghiên cứu cần kiểm soát hiện tượng mệt mỏi nhận thức và sự suy giảm năng lượng của người đánh giá theo thời gian. Khi các phiên đánh giá kéo dài, tài nguyên chú ý của người tham gia tự động giảm đi, dẫn đến sự thiếu nhất quán trong việc xếp hạng hoặc xu hướng đưa ra các phán quyết an toàn (như chọn hòa) ở các tác vụ cuối cùng. Mặc dù mẫu dữ liệu hiện tại đủ lớn để khẳng định các xu hướng chính, các nghiên cứu tiếp theo sẽ đạt chất lượng cao hơn nếu thực hiện trong môi trường kiểm soát chặt chẽ hơn để giảm thiểu các biến động hành vi này và đảm bảo tính đồng đều trong đánh giá trên toàn bộ tập dữ liệu.
- Hệ số overlap tính trực tiếp với văn bản nguồn: Các hệ số ROUGE / BLEU / BERTScore được tính toán so với bài viết gốc, không phải so với bản tóm tắt chuẩn do con người viết, vì hiện tại chưa có bộ dữ liệu benchmark tóm tắt tiếng Việt nào được chú thích bởi con người ở quy mô mà dự án này yêu cầu. Đây là thực tế chung trong các nghiên cứu NLP học thuật tại Việt Nam và đã được khoá luận này thừa nhận như một hạn chế về mặt phương pháp luận của Trục A. Việc đối chiếu đa trực thực hiện trong Mục 4.5 là chốt chặn thực nghiệm quan trọng nhằm tránh việc diễn giải quá đà các điểm số overlap này.

4.7 Tổng kết chương

Chương này đã hoàn thành việc kiểm chứng thực nghiệm toàn diện hệ thống trên 154 bài báo tiếng Việt cân bằng theo năm nhóm chủ đề, và thu được hai nhóm kết quả chính. Nhóm thứ nhất là sự đồng thuận về chiều hướng: cả ba trực đánh giá đều thống nhất rằng phương pháp dung hợp MoA tạo ra bản tóm tắt chất lượng cao hơn bất kỳ mô hình đơn lẻ nào, với ROUGE-1 dẫn +0,062, BERTScore dẫn +0,051, điểm Tổng thể Rubric dẫn +0,08, tỷ lệ thắng đấu cặp LLM-Judge đạt 68,9%, và tỷ lệ ưu tiên của con người đạt 40,9% đa số tương đối. Đặc biệt, trong phép so sánh có kiểm soát mô hình (dung hợp MoA đối đầu GPT-4o đơn lẻ, cùng là đầu ra của GPT-4o), bản dung hợp thắng 37/48 lần ($p = 0,0002$), chứng minh rằng hiệu quả đến từ chính quá trình dung hợp chứ không phải từ sự chênh lệch năng lực mô hình. Nhóm thứ hai là các phát hiện phương pháp luận: khoảng cách 28 điểm phần trăm giữa tỷ lệ thắng của LLM-Judge (68,9%) và tỷ lệ ưu tiên của con người (40,9%) cho thấy LLM-Judge phóng đại biên độ vượt trội; đồng thời, hiện tượng đảo ngược sở thích theo nhóm chủ đề — con người ưa thích bản tóm tắt ngắn nhất cho các bài hành chính khô khan dù LLM-Judge luôn thưởng cho độ bao phủ — khẳng định rằng không một trực đánh giá đơn lẻ nào đủ để phản ánh đầy đủ chất lượng tóm tắt. Chương 5 sẽ tổng hợp các đóng góp khoa học, tái khẳng định các hạn chế và đề xuất các hướng phát triển tương lai.

Chương 5

Kết luận và hướng phát triển

5.1 Tóm tắt các đóng góp

Khóa luận này nghiên cứu xem liệu kiến trúc đa tác nhân phối hợp (MoA) có giúp ích cho bài toán tóm tắt tin tức tiếng Việt hay không, và sâu sắc hơn là liệu các hệ số đánh giá thường dùng cho bài toán tóm tắt tiếng Việt hiện nay có đủ năng lực để phát hiện ra sự giúp ích đó hay không. Khóa luận mang lại ba đóng góp khoa học chính:

(1) **Một hệ thống hoàn chỉnh phục vụ vận hành thực tế (Fiber).** Tiềm ích mở rộng trên trình duyệt xây dựng bằng framework Plasmio, kết hợp dịch vụ backend Next.js triển khai lớp trừu tượng hóa LLM đa nhà cung cấp (hỗ trợ 14 mô hình từ OpenAI, Anthropic và Google), một microservice tính điểm BERTScore bằng ngôn ngữ Python trên nền tảng Hugging Face Spaces, và lớp cơ sở dữ liệu bền vững PostgreSQL quản lý bởi Supabase, đã hoạt động phối hợp để mang lại tính năng tóm tắt thời gian thực.

(2) **Sự ứng dụng kiến trúc MoA cho bài toán tóm tắt có neo ngữ cảnh gốc.** Kiến trúc đề xuất–tổng hợp hai lớp của Wang et al. [8] đã được tái hiện cấu trúc cho tiếng Việt với một cải tiến mang tính nguyên lý then chốt: bài viết nguồn được đưa trực tiếp vào gợi ý của mô hình tổng hợp dưới dạng một kết nối phần dư, tương đồng với Phương trình 1 của nghiên cứu gốc nhưng mở rộng từ chỉ gợi ý đơn thuần sang neo chặt ngữ cảnh nguồn. Kết quả thực nghiệm (Mục 4.2) chứng minh kết nối phần dư này là lựa chọn thiết kế mang tính quyết định: không có nó, mô hình tổng hợp chỉ thực hiện chấp và bản thảo thay vì thực hiện biên tập và dung hợp chi tiết.

(3) **Một khung đánh giá ba trục và phép phản biện thực nghiệm đối với đánh giá một trục.** Các hệ số đo lường khả năng giữ lại nội dung (Trục A), chất lượng đánh giá bằng LLM-Judge và so sánh (Trục B), cùng phương pháp đánh giá xếp hạng của con người kèm đo lường độ đồng thuận (Trục C) được kết hợp chặt chẽ trong một khung đánh giá duy nhất. Thực nghiệm trên 154 bài viết từ *tienphong.vn* chỉ ra bản tóm tắt dung hợp MoA vượt trội hơn mô hình đơn lẻ mạnh nhất trên mọi khía cạnh đánh giá. Sự đồng thuận về mặt chiều hướng trên cả ba góc nhìn độc lập cho phép đưa ra khuyến nghị khoa học vững chắc; bên cạnh đó, khoảng cách chênh lệch lớn giữa Trục B.2a (68,9%) và Trục C (40,9%), cùng hiện tượng đa dạng hành vi đọc của con người trên các chủ đề hành chính khô khan (chọn bản thảo ngắn nhất), chính là những phát hiện phương pháp luận có giá trị mà khung đánh giá ba trục mang lại.

5.2 Hạn chế của đề tài

Khóa luận còn tồn tại ba hạn chế giới hạn phạm vi khẳng định của các luận điểm, tất cả đều đã được thừa nhận trong Chương 4 và được tổng hợp lại ở đây:

- Cấu hình MoA hạn chế: Hệ thống sử dụng một tầng duy nhất với ba mô hình đề xuất. Nghiên cứu của Wang et al. [8] (Bảng 3 và 4) chỉ ra rằng hiệu năng tăng đơn điệu theo độ sâu của tầng tác nhân và số lượng mô hình đề xuất.
- Quy mô nghiên cứu con người và động lực của người đánh giá: Nghiên cứu có sự tham gia của 17 người đánh giá độc lập. Dù đủ lớn để xác định các xu hướng chung, việc phụ thuộc vào nhóm người

tham gia ngẫu nhiên này có thể tạo ra các yếu tố nhiễu do sở thích cá nhân đối với chủ đề bài báo và hiện tượng mệt mỏi nhận thức phát sinh trong các phiên đánh giá kéo dài, gây ảnh hưởng đến độ ổn định của số liệu đo lường.

- Các hệ số trùng lặp tính trực tiếp với văn bản nguồn: Các hệ số ROUGE / BLEU / BERTScore được tính toán trực tiếp với bài viết gốc, không phải so với bản tóm tắt chuẩn do con người viết, vì hiện tại chưa có bộ dữ liệu benchmark tóm tắt tiếng Việt nào được chú thích bởi con người ở quy mô tương tự. Việc đối chiếu chéo đa trực chính là chốt chặn thực nghiệm nhằm tránh việc diễn giải quá đà các kết quả trên Trục A.

5.3 Hướng phát triển

Từ các hạn chế trên, khoá luận đề xuất các hướng phát triển sau:

- Mở rộng Trục C ở quy mô lớn: Thu hút thêm nhiều người đánh giá độc lập để mở rộng quy mô hiện tại (17 người đánh giá) ra toàn bộ cơ sở dữ liệu bài viết thực nghiệm. Cơ sở hạ tầng hệ thống hiện tại đã sẵn sàng để hỗ trợ mở rộng quy mô này, từ đó tinh chỉnh tốt hơn các phép đo đồng thuận giữa các người đánh giá và kiểm soát hiện tượng mệt mỏi nhận thức.
- Các kiến trúc MoA nhiều tầng hơn: Thêm một tầng tổng hợp thứ hai và / hoặc mở rộng số lượng mô hình đề xuất lên năm hoặc sáu mô hình khác nhau. Từ đó xác thực luận điểm tăng trưởng hiệu năng đơn điệu của nghiên cứu gốc [8] đối với tiếng Việt.
- Các tác nhân đề xuất tích hợp RAG: Mỗi mô hình đề xuất có thể tự chủ động truy xuất các thông tin ngữ cảnh nền liên quan (các bài báo cùng ngày, cùng chủ đề) thông qua Tavily; mô hình tổng hợp sau đó sẽ dung hợp để tạo ra bản tóm tắt bao hàm đầy đủ các bối cảnh lịch sử liên quan mà người đọc không cần phải rời mắt khỏi bài báo chính.

TÀI LIỆU THAM KHẢO

- [1] Y. Dubois và cs. “Length-Controlled AlpacaEval: A Simple Way to Debias Automatic Evaluators”. Trong: *arXiv preprint arXiv:2404.04475* (2024).
- [2] J. R. Landis and G. G. Koch. “The Measurement of Observer Agreement for Categorical Data”. Trong: *Biometrics* 33 (1977), tr. 159–174.
- [3] C.-Y. Lin. “ROUGE: A Package for Automatic Evaluation of Summaries”. Trong: *Proceedings of the Workshop on Text Summarization Branches Out (ACL 2004)*. 2004, tr. 74–81.
- [4] C. Nguyen và cs. “ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation”. Trong: *arXiv preprint arXiv:2205.06457* (2022).
- [5] D. Q. Nguyen và cs. “PhoBERT: Pre-trained language models for Vietnamese”. Trong: *Findings of EMNLP 2020*. 2020, tr. 1037–1042.
- [6] Kishore Papineni và cs. “Bleu: a method for automatic evaluation of machine translation”. Trong: *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*. 2002, tr. 311–318.
- [7] A. Vaswani và cs. “Attention Is All You Need”. Trong: *Advances in Neural Information Processing Systems (NeurIPS)* 30 (2017), tr. 5998–6008.
- [8] J. Wang và cs. “Mixture-of-Agents Enhances Large Language Model Capabilities”. Trong: *arXiv preprint arXiv:2406.04692* (2024).
- [9] S. Ye và cs. “FLASK: Fine-grained Language Model Evaluation Based on Alignment Skill Sets”. Trong: *arXiv preprint arXiv:2307.10928* (2023).
- [10] T. Zhang và cs. “BERTScore: Evaluating Text Generation with BERT”. Trong: *Proceedings of the 8th International Conference on Learning Representations (ICLR)*. 2020.
- [11] L. Zheng và cs. “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. Trong: *Advances in Neural Information Processing Systems (NeurIPS)* 36 (2023), tr. 46595–46623.

PHỤ LỤC

Phụ lục A: Minh họa tóm tắt văn bản

Phụ lục này tái hiện một lượt chạy dung hợp MoA điển hình trên bài viết từ *tienphong.vn* có tiêu đề **nu-sinh-lop-8-nghe-an** (*Nữ sinh lớp 8 Nghệ An bị hành hung trên đường đi học về*, một bài viết thuộc chuyên mục Thời sự). Đối với từng bản thảo đề xuất và kết quả dung hợp cuối cùng, toàn văn tiếng Việt được hiển thị dưới đây.

Bản thảo gốc (trích lược, ~ 480 từ): *Ngày 12 tháng 5, Công an huyện Diễn Châu (tỉnh Nghệ An) đã khởi tố vụ án hình sự đối với một nhóm nam thanh niên có hành vi cố ý gây thương tích nghiêm trọng đối với một nữ sinh lớp 8 trên đường đi học về...*

Bản thảo đề xuất 1 (GPT-4o-mini): *Một nữ sinh lớp 8 ở Nghệ An bị hành hung trên đường đi học về, khiến cộng đồng dân cư bức xúc. Công an huyện Diễn Châu đã khởi tố vụ án và xác định nhóm thanh niên gây án. Gia đình nạn nhân yêu cầu xử lý nghiêm minh.*

Bản thảo đề xuất 2 (Claude Haiku 4.5): *Công an huyện Diễn Châu (Nghệ An) khởi tố vụ án cố ý gây thương tích sau khi một nữ sinh lớp 8 bị nhóm nam thanh niên tấn công trên đường đi học về vào chiều ngày 11/5. Nạn nhân hiện đang được điều trị tại bệnh viện huyện; cơ quan điều tra đã triệu tập các đối tượng liên quan.*

Bản thảo đề xuất 3 (Gemini 2.5 Flash): *Vào chiều 11/5/2026, một nữ sinh lớp 8 trên địa bàn xã Diễn Hồng (huyện Diễn Châu, Nghệ An) đã bị một nhóm nam thanh niên hành hung khi đang trên đường đi học về. Sau khi tiếp nhận trình báo, Công an huyện đã khởi tố vụ án; lực lượng chức năng đang truy tìm các đối tượng còn lại.*

Kết quả dung hợp (mô hình tổng hợp GPT-4o): *Chiều 11 tháng 5, một nữ sinh lớp 8 trên địa bàn huyện Diễn Châu, tỉnh Nghệ An, đã bị một nhóm nam thanh niên hành hung trên đường đi học về. Ngày hôm sau, Công an huyện Diễn Châu khởi tố vụ án cố ý gây thương tích và triệu tập các đối tượng liên quan; nạn nhân hiện được điều trị tại bệnh viện huyện. Gia đình nạn nhân và đại diện chính quyền địa phương đề nghị cơ quan tố tụng xử lý nghiêm hành vi tấn công học sinh, đồng thời tăng cường an ninh đoạn đường học sinh đi lại.*

Nhận xét: Bản tóm tắt dung hợp cuối cùng đã thành công trong việc: (i) giữ lại mốc thời gian cụ thể (chiều 11 tháng 5) vốn được cung cấp bởi Claude và Gemini nhưng bị GPT-4o-mini bỏ sót; (ii) giữ lại hành động pháp lý (*khởi tố*) được đề cập trong cả ba bản thảo; (iii) bổ sung thêm ngữ cảnh cơ quan thể chế (lời kêu gọi của gia đình và chính quyền địa phương yêu cầu tăng cường an ninh đoạn đường học sinh đi lại) vốn xuất hiện trong bài gốc nhưng bị cả ba bản thảo bỏ qua. Sự gia tăng của tiêu chí Độ bao phủ (Coverage) (+0,16 trong Mục 4.3.1) chính là trung bình số học của các tác động tương tự như thế này trên 154 bài viết thực nghiệm.

Phụ lục B: Thử nghiệm gợi ý đối với mô hình tổng hợp

Ba biến thể câu lệnh đối với mô hình tổng hợp được tái hiện chi tiết dưới đây. Quá trình phát triển gợi ý phản ánh rõ rệt sự dịch chuyển từ việc chấp vá bản thảo thô sơ sang dung hợp biên tập có neo ngữ cảnh gốc.

Biên thể cơ sở (Chỉ chấp vá bản thảo)

Bạn là một biên tập viên báo chí Việt Nam. Dưới đây là n bản tóm tắt cho cùng một bài báo. Hãy tổng hợp thành một bản tóm tắt cuối cùng, trung lập, văn phong báo chí.

Biên thể v1: Neo nguồn nghiêm ngặt (Thêm kết nối phần dư)

[Nội dung gợi ý cơ sở...]

KHÔNG được thêm thông tin không có trong bài báo gốc dưới đây:

<article>

{{source_text}}

</article>

Tác động: Thay đổi hoàn toàn hành vi từ chấp vá bản thảo sang dung hợp sâu sắc. Điểm ROUGE-1 so với bài gốc giảm từ 0.34 xuống 0.24, thể hiện mật độ trừu tượng hóa (abstractive density) cao hơn.

Biên thể v2: Neo nguồn linh hoạt (Phiên bản hiện sử dụng)

[Nội dung gợi ý cơ sở...]

Bài báo gốc được cung cấp dưới đây để tham khảo:

<article>

{{source_text}}

</article>

Lưu ý: Cụm từ "cô đọng"(condense) đã được loại bỏ trong cập nhật cuối cùng để ngăn mô hình tạo ra các kết quả quá ngắn ngủi như các bản thảo thô. Thay đổi này giúp cải thiện mạch văn ngữ nghĩa và phong cách báo chí của bản tóm tắt cuối cùng.

Phát hiện (tái khẳng định): Sự xuất hiện đơn thuần của văn bản gốc trong ngữ cảnh của mô hình tổng hợp giúp thay đổi hoàn toàn hành vi của mô hình từ chấp vá bản thảo sang dung hợp biên tập. Các quy tắc chi tiết (v1 nghiêm ngặt so với v2 linh hoạt) không làm biến động mạnh các hệ số định lượng, nhưng việc loại bỏ các ràng buộc văn phong như từ “cô đọng” lại là yếu tố quyết định để đạt được phong cách báo chí chuẩn mực, sang trọng.