

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



**CẢI TIẾN MÔ HÌNH ViT5 DỰA TRÊN KỸ THUẬT
CHỌN LỌC NGỮ CẢNH DÀI VÀ RERANKING CHO
BÀI TOÁN TÓM TẮT VĂN BẢN TIẾNG VIỆT**

Học phần: Xử lý ngôn ngữ tự nhiên

Giáo viên: TS. Trần Hồng Việt

Người thực hiện: Phạm Văn Anh – 22028099
Bùi Đức Duy – 22021201
Lê Văn Thắng – 22028313
Nguyễn Tiến Mạnh – 24020220

HÀ NỘI – 2026

TỶ LỆ ĐÓNG GÓP

Bảng dưới đây trình bày phân công nhiệm vụ và tỷ lệ đóng góp của từng thành viên trong nhóm đối với báo cáo và sản phẩm bài tập lớn.

STT	Họ và tên	MSSV	Vai trò & Nhiệm vụ chính	Tỷ lệ (%)
1	Phạm Văn Anh	22028099	Xây dựng evaluation service, script đánh giá	24%
2	Bùi Đức Duy	22021201	Phối hợp báo cáo & Thuyết trình	24%
3	Lê Văn Thắng	22028313	Thực nghiệm đối chứng & Thống kê và soạn thảo báo cáo	24%
4	Nguyễn Tiến Mạnh	24020220	Thiết kế Pipeline HLK-ViT5 (Selective Long-Context, MMR, Reranker)	28%
			Tổng cộng	100%

Bảng 1: Phân công nhiệm vụ và tỷ lệ đóng góp của các thành viên trong nhóm

TÓM TẮT BÁO CÁO

Tóm tắt văn bản tự động cho tiếng Việt, đặc biệt đối với thể loại báo chí ngữ cảnh dài, vẫn còn nhiều thách thức lớn. Các mô hình tóm tắt trừu tượng hóa dựa trên kiến trúc Transformer tiền huấn luyện như ViT5-base thường chịu rào cản giới hạn độ dài đầu vào (thường chỉ xử lý được từ 256 đến 512 tokens), dẫn đến hiện tượng trích đoạn đầu và bỏ sót các dữ kiện quan trọng nằm ở phần giữa hoặc cuối văn bản. Bên cạnh đó, hiện tượng ảo giác và sự mất nhất quán về thực thể hay con số vẫn là rào cản lớn đối với chất lượng bản tóm tắt sinh ra.

Báo cáo này đề xuất HKL-ViT5, một pipeline cải tiến toàn diện cho bài toán tóm tắt văn bản tiếng Việt ngữ cảnh dài dựa trên xương sống **VietAI/ViT5-base**. Hệ thống tích hợp hai kỹ thuật cốt lõi: (1) Selective Long-Context, kết hợp chia đoạn dựa trên câu với khoảng giao đề 1 câu, chấm điểm nổi bật và thuật toán Maximal Marginal Relevance (MMR) để lọc ra tối đa 4 đoạn ngữ cảnh đại diện nhất từ toàn văn bài báo mà không bị dư thừa thông tin, cho phép mở rộng cửa sổ ngữ cảnh đầu vào lên tới 1024 tokens; (2) Heuristic Factuality Reranking, sinh nhiều bản tóm tắt ứng viên và xếp hạng lại dựa trên độ chính xác thực thể và tính nhất quán số liệu nhằm giảm thiểu tối đa hiện tượng ảo giác.

Thực nghiệm được triển khai trên tập kiểm thử độc lập gồm 300 bài báo thu thập từ domain *tienphong.vn*. Kết quả được đối chiếu toàn diện với hai mô hình baseline mạnh **Nishikyen/vit5-vietnamese-news** và **thnhan/sft_model**. HKL-ViT5 đạt điểm ROUGE-1 0.5184 (so với 0.4707 và 0.4321), BERTScore F1 0.9008 (so với 0.8934 và 0.8874), độ chính xác con số tiệm cận tuyệt đối 98.54%, đồng thời kéo giảm tỷ lệ ảo giác xuống 39.04% (so với 45.53% và 48.45%). Các kết quả khẳng định tính vượt trội của HKL-ViT5 trong việc bảo toàn ngữ cảnh toàn văn và giữ vững độ trung thực dữ kiện.

Từ khoá: Tóm tắt văn bản tiếng Việt, ViT5, HKL-ViT5, Selective Long-Context, MMR, Factuality Reranking, *tienphong.vn*.

MỤC LỤC

TỶ LỆ ĐÓNG GÓP	i
TÓM TẮT BÁO CÁO	ii
MỤC LỤC	iii
DANH MỤC HÌNH VẼ	v
DANH MỤC BẢNG BIỂU	vi
DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT	vii
Chương 1: Giới thiệu	1
1.1 Bối cảnh và động lực nghiên cứu	1
1.2 Các công trình liên quan và khoảng trống nghiên cứu	1
1.3 Mục tiêu và đóng góp chính	2
1.4 Cấu trúc báo cáo	2
1.5 Tổng kết chương	3
Chương 2: Cơ sở lý thuyết	4
2.1 Mô hình ViT5 và Kiến trúc Transformer	4
2.1.1 Kiến trúc Transformer Encoder-Decoder	4
2.1.2 Mô hình tiền huấn luyện ViT5	4
2.2 Các kỹ thuật xử lý ngữ cảnh và trích chọn thông tin	5
2.2.1 Sentence-aware Chunking và Overlapping	5
2.2.2 Maximal Marginal Relevance (MMR)	5
2.2.3 Keyword-conditioned Generation	5
2.3 Các mô hình đối chứng	5
2.4 Hệ đo lường đánh giá chất lượng tóm tắt	5
2.4.1 Nhóm 1: Lexical Overlap (Độ trùng lặp từ vựng)	5
2.4.2 Nhóm 2: Semantic Quality (Chất lượng ngữ nghĩa)	6
2.4.3 Nhóm 3: Factual Consistency (Tính nhất quán sự thật)	6
2.4.4 Nhóm 4: Performance (Hiệu năng tính toán)	6
2.5 Tổng kết chương	6
Chương 3: Phương pháp đề xuất	7
3.1 Tổng quan kiến trúc Pipeline HLK-ViT5	7
3.2 Bộ dữ liệu thực nghiệm	7
3.3 Chi tiết các Module cải tiến cốt lõi	8
3.3.1 Sentence-aware Chunking và Overlapping	8
3.3.2 Saliency Scoring và Lọc ngữ cảnh bằng MMR	8

3.3.3	Input Formatting và Keyword Conditioning	8
3.3.4	Fine-tuning mô hình ViT5-base và phát hành Checkpoint	8
3.3.5	Candidate Generation và Heuristic Factuality Reranker	9
3.4	Thiết lập thực nghiệm và Siêu tham số	9
3.5	Tổng kết chương	9
Chương 4:	Kết quả thực nghiệm	10
4.1	Thiết lập đánh giá và định dạng dữ liệu	10
4.1.1	Tập dữ liệu kiểm thử và các mô hình so sánh	10
4.1.2	Cấu trúc định dạng đầu ra dữ liệu	10
4.2	Kết quả nhóm 1: Lexical Overlap (ROUGE)	11
4.3	Kết quả nhóm 2: Semantic Quality (BERTScore)	11
4.4	Kết quả nhóm 3: Factual Consistency (Tính nhất quán sự thật)	11
4.5	Kết quả nhóm 4: Performance (Hiệu năng suy luận)	12
4.6	Tổng kết chương	13
Chương 5:	Phân tích kết quả thực nghiệm	14
5.1	Phân tích ý nghĩa kết quả	14
5.2	Phân tích lỗi	14
5.3	Phân tích sự đánh đổi hiệu năng	15
5.4	Hạn chế của nghiên cứu	15
5.5	Tổng kết chương	15
Chương 6:	Kết luận và hướng phát triển	16
6.1	Tóm tắt các kết quả và đóng góp chính	16
6.2	Hướng phát triển tương lai	16
TÀI LIỆU THAM KHẢO		17
PHỤ LỤC		18

DANH MỤC HÌNH VẼ

3.1 Sơ đồ luồng xử lý 13 bước trong kiến trúc pipeline HLK-ViT5.	7
--	---

DANH MỤC BẢNG BIỂU

1	Phân công nhiệm vụ và tỷ lệ đóng góp của các thành viên trong nhóm	i
3.1	Cấu hình siêu tham số huấn luyện mô hình HLK-ViT5	9
4.1	Kết quả đánh giá nhóm Lexical Overlap (ROUGE F1 Macro trên 300 mẫu). In đậm: Kết quả tốt nhất.	11
4.2	Kết quả đánh giá nhóm Semantic Quality (BERTScore với <code>xlm-roberta-base</code>). In đậm: Kết quả tốt nhất.	11
4.3	Kết quả đánh giá nhóm Factual Consistency. Entity Precision, Number Consistency: càng cao càng tốt; Contradiction Rate, Hallucination Rate: càng thấp càng tốt. In đậm: Tốt nhất.	12
4.4	Thống kê số lượng thực thể, con số và xác suất kéo theo NLI.	12
4.5	Kết quả thống kê thời gian suy luận (Inference Time). In đậm: Tốc độ nhanh nhất.	13
6.1	Cấu hình chi tiết môi trường thực nghiệm HLK-ViT5	18

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Chữ viết tắt	Nghĩa đầy đủ / Giải thích
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BERT	Bidirectional Encoder Representations from Transformers
BERTScore	Chỉ số đánh giá tương đồng ngữ nghĩa dựa trên vector ngữ cảnh BERT
GUID	Globally Unique Identifier (Mã định danh duy nhất toàn cầu)
LLM	Large Language Model (Mô hình ngôn ngữ lớn)
MMR	Maximal Marginal Relevance — Thuật toán chọn lọc nội dung nổi bật và giảm dư thừa
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
ROUGE	Recall-Oriented Understudy for Gisting Evaluation — Bộ độ đo trùng lặp n-gram
Seq2Seq	Sequence-to-Sequence (Mô hình biến đổi chuỗi sang chuỗi)
SFT	Supervised Fine-Tuning (Huấn luyện tinh chỉnh có giám sát)
ViT5	Vietnamese Text-to-Text Transfer Transformer (Mô hình T5 cho tiếng Việt)

Thuật ngữ	Định nghĩa
Abstractive Summarization	Tóm tắt trừu tượng hóa: Sinh câu mới diễn giải lại nội dung văn bản gốc
Extractive Summarization	Tóm tắt trích xuất: Trích chọn nguyên văn các câu quan trọng từ bài gốc
Selective Long-Context	Kỹ thuật chọn lọc các đoạn ngữ cảnh quan trọng rải rác trong toàn văn bản dài
Sentence-aware Chunking	Phương pháp chia đoạn văn bản dựa theo ranh giới câu chuẩn xác
Overlapping Chunks	Kỹ thuật chia đoạn có khoảng đè câu nhằm bảo toàn tính liên kết ngữ cảnh
Keyword-conditioned Gen.	Cơ chế điều kiện hóa quá trình sinh văn bản của mô hình bằng danh sách từ khóa
Factuality Reranker	Bộ xếp hạng lại ứng viên tóm tắt nhằm tối ưu độ chính xác thực thể và số liệu
Hallucination	Hiện tượng ảo giác: Mô hình sinh ra các thông tin sai lệch không có trong nguồn

Chương 1

Giới thiệu

Chương này đặt nền móng cho toàn bộ báo cáo bằng việc giới thiệu bài toán tóm tắt văn bản tiếng Việt ngữ cảnh dài, phân tích những thách thức cốt lõi của các mô hình Sequence-to-Sequence hiện nay và trình bày giải pháp cải tiến HKL-ViT5 dựa trên kiến trúc ViT5-base. Mục 1.1 trình bày bối cảnh và động lực nghiên cứu; Mục 1.2 khảo sát các công trình liên quan và xác định khoảng trống nghiên cứu; Mục 1.3 nêu rõ mục tiêu và các đóng góp khoa học chính; Mục 1.4 mô tả cấu trúc tổng quan của báo cáo; và Mục 1.5 tổng kết chương.

1.1 Bối cảnh và động lực nghiên cứu

Trong kỷ nguyên bùng nổ thông tin số, khối lượng tin tức báo chí tiếng Việt được xuất bản hàng ngày trên các trang báo điện tử lớn như *tienphong.vn* gia tăng với tốc độ phi mã. Việc tiếp nhận và xử lý lượng thông tin đồ sộ này đặt ra nhu cầu cấp thiết về các công cụ tóm tắt văn bản tự động. Tóm tắt văn bản hỗ trợ người đọc nhanh chóng nắm bắt các dữ kiện then chốt mà không cần đọc toàn văn bài báo dài.

Các phương pháp tóm tắt được chia thành hai nhóm chính: tóm tắt trích xuất và tóm tắt trừu tượng hóa. Nếu như các phương pháp trích xuất chỉ đơn thuần lựa chọn và chắp vá các câu nguyên văn từ bài gốc, thì tóm tắt trừu tượng hóa dựa trên các mô hình ngôn ngữ tiền huấn luyện có khả năng diễn giải, cô đọng và sinh ra các bản tóm tắt trôi chảy, tự nhiên như con người biên soạn. Tại Việt Nam, mô hình ViT5 [1] dựa trên kiến trúc T5 Encoder-Decoder đã chứng minh hiệu năng ấn tượng trong nhiều tác vụ sinh ngôn ngữ tự nhiên.

Tuy nhiên, khi áp dụng mô hình ViT5-base vào bài toán tóm tắt tin tức báo chí thực tế, nghiên cứu nhận thấy hai thách thức lớn chưa được giải quyết triệt để:

- **Giới hạn cửa sổ ngữ cảnh:** Các mô hình ViT5-base chuẩn thường đặt độ dài đầu vào tối đa là 256 hoặc 512 tokens. Đối với các bài báo chí dài (thường vượt quá 1000 từ), việc cắt bỏ phần sau văn bản khiến mô hình mắc phải thiên kiến trích đoạn đầu và bỏ sót các thông tin diễn biến, kết luận quan trọng ở phần giữa hoặc cuối bài.
- **Hiện tượng ảo giác và mất nhất quán dữ kiện:** Các mô hình trừu tượng hóa có xu hướng “bịa” ra thông tin hoặc làm sai lệch các thực thể (tên người, địa danh, tổ chức) và các con số thống kê so với văn bản gốc. Điều này làm giảm nghiêm trọng độ tin cậy của bản tóm tắt trong báo chí.

Động lực của đề tài này là xây dựng một pipeline cải tiến có tên HKL-ViT5, giúp mô hình ViT5-base vượt qua rào cản độ dài đầu vào bằng cơ chế chọn lọc ngữ cảnh thông minh và đảm bảo tính trung thực thông tin thông qua bộ lọc xếp hạng lại dữ kiện.

1.2 Các công trình liên quan và khoảng trống nghiên cứu

Bài toán tóm tắt văn bản tiếng Việt đã thu hút nhiều công trình nghiên cứu trong những năm gần đây:

- **Mô hình ViT5 và các biến thể Fine-tune:** Nguyen et al. [1] giới thiệu ViT5 tiền huấn

luyện trên corpus tiếng Việt quy mô lớn. Sau đó, nhiều mô hình fine-tune mã nguồn mở như Nishikyen/vit5-vietnamese-news và thnhan/sft_model đã được triển khai cho tóm tắt tin tức. Tuy nhiên, các mô hình này chủ yếu áp dụng quy trình fine-tune chuẩn trên chuỗi cắt ngắn, chưa giải quyết triệt để bài toán ngữ cảnh dài toàn văn.

- **Kỹ thuật nén ngữ cảnh và chọn lọc đoạn văn:** Nhiều nghiên cứu trên thế giới đã sử dụng các thuật toán như MMR hay Saliency Scoring để nén tài liệu trước khi đưa vào LLM/Seq2Seq. Tuy nhiên, việc kết hợp giữa chia đoạn bảo toàn câu, đề câu liên kết và điều kiện hóa từ khóa cho mô hình ViT5 tiếng Việt vẫn chưa được nghiên cứu hệ thống.
- **Đánh giá và kiểm soát tính xác thực:** Hầu hết các bài báo hiện nay chỉ dừng lại ở việc báo cáo chỉ số ROUGE và BERTScore. Việc đưa ra một quy trình reranking chuyên biệt nhằm kiểm soát tính nhất quán của thực thể và con số cho tiếng Việt vẫn là một khoảng trống lớn.

Từ khảo sát trên, đề tài xác định khoảng trống nghiên cứu cốt lõi: *Chưa có một kiến trúc pipeline ViT5 tiếng Việt tích hợp đồng thời cơ chế chọn lọc ngữ cảnh dài không dư thừa và bộ lọc kiểm soát ảo giác.*

1.3 Mục tiêu và đóng góp chính

Mục tiêu chính của đề tài là thiết kế, cài đặt và đánh giá mô hình HKL-ViT5 cho bài toán tóm tắt văn bản tiếng Việt ngữ cảnh dài từ báo điện tử *tienphong.vn*.

Đề tài đóng góp bốn điểm mới về mặt kỹ thuật và thực nghiệm:

1. **Cơ chế Selective Long-Context:** Thiết kế pipeline chia đoạn bảo toàn câu, giao đề 1 câu, chấm điểm nổi bật kết hợp thuật toán MMR để chọn ra tối đa 4 đoạn ngữ cảnh quan trọng nhất từ toàn văn bài báo, cho phép mở rộng đầu vào ViT5 lên 1024 tokens mà không làm mất tính liên kết.
2. **Kỹ thuật Keyword-conditioned Generation:** Trích xuất từ khóa chủ đề và nhúng trực tiếp vào đầu chuỗi prompt đầu vào của ViT5 để định hướng mô hình tập trung vào các nội dung trọng tâm.
3. **Heuristic Factuality Reranker:** Xây dựng bộ lọc xếp hạng lại đa ứng viên sinh ra từ ViT5, ưu tiên các bản tóm tắt bảo toàn chính xác danh từ riêng và số liệu thực tế.
4. **Đánh giá đa chiều trên Corpus 300 mẫu:** Thực nghiệm trên tập kiểm thử 300 mẫu báo chí độc lập từ domain *tienphong.vn*, so sánh toàn diện với hai baseline Nishikyen và thnhan trên 4 nhóm độ đo.

1.4 Cấu trúc báo cáo

Báo cáo được tổ chức theo cấu trúc IMRaD chuẩn gồm 6 chương: Chương 1 giới thiệu tổng quan đề tài, mục tiêu và đóng góp. Chương 2 xây dựng cơ sở lý thuyết về ViT5, kiến trúc Transformer, các thuật toán nén ngữ cảnh và hệ đo lường đánh giá. Chương 3 trình bày chi tiết phương pháp đề xuất HKL-ViT5, kiến trúc pipeline 13 bước và thiết lập thực nghiệm. Chương 4 báo cáo kết quả thực nghiệm định lượng trên bộ dữ liệu kiểm thử. Chương 5 phân tích, bình luận ý nghĩa kết quả, phân tích lỗi và thảo luận hạn chế. Chương 6 kết luận và đề xuất các hướng phát triển tương lai.

1.5 Tổng kết chương

Chương này đã làm rõ động lực phát triển mô hình HKL-ViT5 nhằm khắc phục hai hạn chế lớn của ViT5-base: rào cản độ dài đầu vào và hiện tượng ảo giác dữ kiện. Chương cũng đã xác định khoảng trống nghiên cứu, phát biểu 4 đóng góp kỹ thuật chính và phác thảo cấu trúc báo cáo. Các nền tảng lý thuyết cần thiết sẽ được trình bày chi tiết trong Chương 2.

Chương 2

Cơ sở lý thuyết

Chương này xây dựng nền tảng lý thuyết cho toàn bộ các mô hình và thuật toán được sử dụng trong HLK-ViT5. Mục 2.1 trình bày kiến trúc Transformer Encoder-Decoder và mô hình ViT5-base; Mục 2.2 trình bày các kỹ thuật nén ngữ cảnh và trích chọn thông tin như MMR và Keyword Conditioning; Mục 2.3 giới thiệu các mô hình baseline đối chứng; Mục 2.4 định nghĩa chi tiết 4 nhóm độ đo đánh giá chất lượng tóm tắt; và Mục 2.5 tổng kết chương.

2.1 Mô hình ViT5 và Kiến trúc Transformer

2.1.1 Kiến trúc Transformer Encoder-Decoder

Kiến trúc Transformer [3] dựa trên cơ chế chú ý, loại bỏ hoàn toàn các vòng lặp hồi quy để cho phép tính toán song song hóa trên quy mô lớn. Đối với bài toán sinh văn bản dạng Sequence-to-Sequence, kiến trúc Encoder-Decoder bao gồm hai khối chính:

- **Bộ mã hóa (Encoder):** Tiếp nhận chuỗi token đầu vào $X = (x_1, x_2, \dots, x_n)$, sử dụng các lớp chú ý bản thân đa đầu và mạng truyền thẳng để tạo ra tập hợp các biểu diễn ngữ cảnh ẩn $H = (h_1, h_2, \dots, h_n)$.
- **Bộ giải mã (Decoder):** Tự điều khiển sinh chuỗi đầu ra $Y = (y_1, y_2, \dots, y_m)$ theo từng bước. Tại mỗi bước t , bộ giải mã kết hợp chú ý bản thân có mặt nạ trên các token đã sinh $(y_1, \dots, y_{t-1})$ và chú ý chéo trên chuỗi ẩn H của Encoder.

Công thức chú ý tích vô hướng có tỷ lệ với truy vấn Q , khóa K và giá trị V được định nghĩa:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

trong đó d_k là chiều của khóa.

2.1.2 Mô hình tiền huấn luyện ViT5

ViT5 [1] là mô hình ngôn ngữ tiếng Việt được xây dựng dựa trên kiến trúc T5 (Text-to-Text Transfer Transformer). ViT5 chuyển đổi tất cả các tác vụ NLP (phân loại, dịch máy, tóm tắt) về dạng bài toán chuỗi-sang-chuỗi: nhận đầu vào là một chuỗi văn bản và sinh đầu ra là một chuỗi văn bản.

Phiên bản **VietAI/ViT5-base** có 12 lớp Encoder, 12 lớp Decoder, chiều ẩn $d_{\text{model}} = 768$, 12 đầu chú ý và khoảng 220 triệu tham số. Mô hình được tiền huấn luyện trên tập dữ liệu tiếng Việt quy mô lớn với mục tiêu khôi phục token bị che. ViT5 là mô hình nền tảng được chọn để xây dựng và tinh chỉnh trong đề tài HLK-ViT5.

2.2 Các kỹ thuật xử lý ngữ cảnh và trích chọn thông tin

2.2.1 Sentence-aware Chunking và Overlapping

Khi độ dài bài báo vượt quá cửa sổ xử lý của Encoder, văn bản cần được phân rã thành các đoạn nhỏ (chunks). Kỹ thuật phân đoạn theo ranh giới câu đảm bảo không cắt đôi câu giữa chừng, giữ nguyên tính hoàn chỉnh cú pháp. Thêm vào đó, việc duy trì khoảng dè 1 câu giữa hai chunk kế nhau giúp bảo toàn mối quan hệ tham chiếu ngữ nghĩa giữa các đoạn.

2.2.2 Maximal Marginal Relevance (MMR)

Thuật toán Maximal Marginal Relevance (MMR) được thiết kế nhằm chọn ra tập hợp các câu/đoạn văn có độ tương quan cao nhất với chủ đề nhưng đồng thời tối thiểu hóa sự trùng lặp thông tin nội bộ. Với tập hợp ứng viên C , tập đã chọn S , truy vấn/từ khóa Q , chỉ số MMR của một ứng viên $c_i \in C \setminus S$ được tính:

$$\text{MMR}(c_i) = \arg \max_{c_i \in C \setminus S} \left[\lambda \cdot \text{Sim}_1(c_i, Q) - (1 - \lambda) \cdot \max_{c_j \in S} \text{Sim}_2(c_i, c_j) \right]$$

trong đó Sim_1 đo độ nổi bật của chunk so với bài báo/từ khóa, Sim_2 đo độ tương đồng giữa hai chunk, và $\lambda \in [0, 1]$ là hệ số cân bằng giữa độ nổi bật và tính đa dạng.

2.2.3 Keyword-conditioned Generation

Keyword-conditioned Generation là kỹ thuật bổ sung danh sách từ khóa đại diện vào trước ngữ cảnh đầu vào của bộ mã hóa. Bằng cách định dạng chuỗi đầu vào dưới dạng:

Keywords: [từ_khóa_1, từ_khóa_2, ...] | Context: [nội_dung_đã_lọc]

mô hình ViT5 được gợi ý tập trung chú ý vào các thực thể và khái niệm trung tâm khi sinh bản tóm tắt.

2.3 Các mô hình đối chứng

Đề tài đưa hai mô hình mã nguồn mở hiện có vào so sánh đối chứng:

- **Nishikyen/vit5-vietnamese-news:** Mô hình ViT5-base được fine-tune trên tập dữ liệu tin tức tiếng Việt theo phương pháp chuẩn hóa truyền thống với chiều dài input giới hạn 256/512 tokens.
- **thnhan/sft_model:** Mô hình ViT5-base được tinh chỉnh theo phương pháp SFT tập trung vào khả năng sinh câu trôi chảy.

2.4 Hệ đo lường đánh giá chất lượng tóm tắt

Để đánh giá toàn diện HLK-ViT5, nghiên cứu xây dựng bộ đo lường 4 nhóm:

2.4.1 Nhóm 1: Lexical Overlap (Độ trùng lặp từ vựng)

- **ROUGE-1 / ROUGE-2:** Đo độ trùng lặp n -gram ($n = 1, 2$) giữa bản tóm tắt mô hình C và tham chiếu R .
- **ROUGE-L:** Đo độ dài chuỗi con chung dài nhất.

2.4.2 Nhóm 2: Semantic Quality (Chất lượng ngữ nghĩa)

- **BERTScore:** Sử dụng vector nhúng ngữ cảnh từ mô hình PhoBERT [2] để tính độ tương đồng cosine tốt nhất giữa các token, phản ánh sự tương đồng ngữ nghĩa ngay cả khi từ ngữ được diễn đạt lại.

2.4.3 Nhóm 3: Factual Consistency (Tính nhất quán sự thật)

- **Entity Precision:** Tỷ lệ phần trăm các thực thể (tên riêng, tổ chức, địa danh) xuất hiện trong bản tóm tắt được xác nhận có mặt chính xác trong bài gốc.
- **Number Consistency:** Tỷ lệ bảo toàn chính xác các con số và dữ liệu thống kê.
- **Contradiction Rate / Hallucination Rate:** Tỷ lệ phần trăm các mệnh đề trong bản tóm tắt mâu thuẫn hoặc “bịa” thêm so với nguồn gốc.

2.4.4 Nhóm 4: Performance (Hiệu năng tính toán)

- **Inference Time:** Thời gian xử lý trung bình (tính bằng giây) để tạo ra bản tóm tắt hoàn chỉnh cho một văn bản đầu vào.

2.5 Tổng kết chương

Chương này đã cung cấp nền tảng lý thuyết về mô hình ViT5, kiến trúc Transformer Encoder-Decoder, thuật toán MMR, kỹ thuật Keyword Conditioning và hệ đo lường 4 nhóm. Chương 3 sẽ trình bày cách các lý thuyết này được tích hợp vào kiến trúc pipeline HLK-ViT5.


Chương 3

Phương pháp đề xuất

Chương này trình bày chi tiết thiết kế và hiện thực hóa kiến trúc pipeline HLK-ViT5. Mục 3.1 tổng quan luồng xử lý toàn hệ thống; Mục 3.2 mô tả bộ dữ liệu thực nghiệm 15.620 mẫu từ *tienphong.vn*; Mục 3.3 chi tiết hóa 5 module cải tiến cốt lõi; Mục 3.4 trình bày thiết lập siêu tham số huấn luyện; và Mục 3.5 tổng kết chương.

3.1 Tổng quan kiến trúc Pipeline HLK-ViT5

Pipeline HLK-ViT5 được xây dựng nhằm giải quyết bài toán tóm tắt văn bản tin tức ngữ cảnh dài thông qua quy trình xử lý 13 bước được tự động hóa hoàn toàn. Kiến trúc tổng thể của hệ thống được thể hiện trong Sơ đồ bên dưới.



Hình 3.1: Sơ đồ luồng xử lý 13 bước trong kiến trúc pipeline HLK-ViT5.

Luồng xử lý đi từ văn bản bài báo gốc, trải qua công đoạn tiền xử lý, phân đoạn nén ngữ cảnh thông minh bằng MMR, ghép chuỗi điều kiện hóa từ khóa, đưa qua mô hình ViT5-base và cuối cùng lọc qua bộ xếp hạng lại tính xác thực để xuất bản tóm tắt tối ưu.

3.2 Bộ dữ liệu thực nghiệm

Nghiên cứu xây dựng và sử dụng bộ dữ liệu corpus tin tức tiếng Việt được thu thập trực tiếp từ trang báo điện tử *tienphong.vn*. Bộ dữ liệu bao gồm các đặc điểm chính:

- **Quy mô tập huấn luyện:** 15.620 cặp văn bản gốc và bản tóm tắt tiêu chuẩn.
- **Đặc trưng ngữ cảnh:** Độ dài văn bản gốc trung bình từ 800 đến 1.500 từ, bao phủ nhiều thể loại báo chí khác nhau như Thời sự, Kinh tế, Pháp luật, Văn hóa và Xã hội.
- **Chuẩn hóa dữ liệu:** Tất cả văn bản được xử lý khoảng trắng thừa, sửa lỗi mã hóa Unicode dựng sẵn và tách từ tiếng Việt.

3.3 Chi tiết các Module cải tiến cốt lõi

3.3.1 Sentence-aware Chunking và Overlapping

Bài báo gốc sau khi chuẩn hóa được tách thành danh sách các câu hoàn chỉnh $S = (s_1, s_2, \dots, s_K)$. Quá trình phân đoạn được thực hiện bằng cách gom các câu liên tiếp sao cho tổng số token của mỗi chunk C_j không vượt quá 256 tokens:

$$|C_j| \leq 256 \text{ tokens}$$

Nhằm tránh làm gãy đứt ngữ cảnh giao thoa giữa hai đoạn kề nhau, chunk C_{j+1} luôn giữ lại câu cuối cùng của chunk C_j làm câu mở đầu (overlap 1 câu).

3.3.2 Salience Scoring và Lọc ngữ cảnh bằng MMR

Mỗi chunk C_j được tính điểm tổng hợp dựa trên 3 thành phần:

$$\text{Score}(C_j) = \alpha \cdot \text{KeywordCoverage}(C_j) + \beta \cdot \text{Salience}(C_j) + \gamma \cdot \text{PositionScore}(C_j)$$

trong đó:

- $\text{KeywordCoverage}(C_j)$ đo tỷ lệ từ khóa chủ đề xuất hiện trong chunk.
- $\text{Salience}(C_j)$ tính độ nổi bật thông tin dựa trên điểm TF-IDF trung bình của các thuật ngữ.
- $\text{PositionScore}(C_j)$ thưởng điểm cho các chunk nằm ở đoạn đầu và đoạn kết của bài báo.

Sau khi tính điểm, thuật toán MMR chọn lọc ra tối đa 4 chunk có điểm số cao nhất nhưng không trùng lặp ngữ nghĩa với các chunk đã chọn. Bốn chunk này sau đó được khôi phục về đúng vị trí xuất hiện ban đầu trong bài báo để đảm bảo tính tuyến tính của mạch văn.

3.3.3 Input Formatting và Keyword Conditioning

Bốn chunk chọn lọc được nối lại thành ngữ cảnh đại diện $\tilde{X}$. Danh sách từ khóa quan trọng $K = \{k_1, k_2, \dots, k_m\}$ được trích xuất và đặt ở vị trí đầu chuỗi prompt:

$$\text{tóm tắt: Từ khóa: } k_1, k_2, \dots, k_m \mid \text{Ngữ cảnh: } \tilde{X}$$

Cấu trúc input này mở rộng cửa sổ ngữ cảnh hiệu quả của ViT5 lên đến 1024 tokens, cho phép mô hình tiếp nhận thông tin bao quát toàn văn bài báo.

3.3.4 Fine-tuning mô hình ViT5-base và phát hành Checkpoint

Mô hình VietAI/ViT5-base được tinh chỉnh có giám sát trên tập 15.620 mẫu với hàm mất mát Cross-Entropy chuẩn cho bài toán sinh chuỗi:

$$\mathcal{L}_{\text{CE}}(\theta) = - \sum_{t=1}^T \log P_{\theta}(y_t \mid y_{<t}, \tilde{X}, K)$$

Trọng số mô hình sau khi huấn luyện tinh chỉnh đã được đóng gói và phát hành công khai trên kho lưu trữ Hugging Face Hub tại địa chỉ: <https://huggingface.co/tmanh217/hlk-vit5>.

3.3.5 Candidate Generation và Heuristic Factuality Reranker

Trong giai đoạn suy luận, thay vì chỉ sinh 1 bản tóm tắt bằng giải thuật Beam Search thông thường, ViT5-base được cấu hình sinh ra $N = 5$ ứng viên tóm tắt $\{Y_1, Y_2, \dots, Y_N\}$.

Bộ xếp hạng lại Heuristic Factuality Reranker chấm điểm từng ứng viên Y_i dựa trên hai tiêu chí:

- **Entity Consistency Score:** Phạt nặng các ứng viên xuất hiện tập thực thể $E(Y_i)$ không nằm trong tập thực thể bài gốc $E(X)$.
- **Number Accuracy Score:** So sánh tập các con số $N(Y_i)$ với $N(X)$, loại bỏ các bản tóm tắt làm sai lệch số liệu.

Bản tóm tắt Y^* có điểm Reranker cao nhất được chọn làm kết quả xuất ra cuối cùng.

3.4 Thiết lập thực nghiệm và Siêu tham số

Bảng 3.1 tóm tắt các siêu tham số chính được sử dụng trong quá trình huấn luyện HLK-ViT5.

Bảng 3.1: Cấu hình siêu tham số huấn luyện mô hình HLK-ViT5

Siêu tham số	Giá trị thiết lập
Mô hình nền	VietAI/ViT5-base
Hugging Face Checkpoint	https://huggingface.co/tmanh217/hlk-vit5
Độ dài đầu vào tối đa	1024 tokens
Độ dài đầu ra tối đa	256 tokens
Tốc độ học (Learning Rate)	5×10^{-5} (với AdamW optimizer)
Kích thước Batch (Batch Size)	16 (với gradient accumulation)
Số lượng Epochs	5 epochs
Số lượng Candidate Rerank (N)	5 candidates
Hệ số MMR (λ)	0,7

3.5 Tổng kết chương

Chương này đã chi tiết hóa kiến trúc 13 bước của HLK-ViT5, kết hợp giữa chia đoạn bảo toàn câu, nén ngữ cảnh MMR, Keyword Conditioning và Heuristic Factuality Reranker. Toàn bộ thiết lập này được huấn luyện trên 15.620 mẫu dữ liệu *tienphong.vn*. Chương 4 sẽ báo cáo kết quả thực nghiệm định lượng.

Chương 4

Kết quả thực nghiệm

Chương này báo cáo kết quả thực nghiệm định lượng chi tiết của mô hình HKL-ViT5 và hai mô hình đối chứng trên tập dữ liệu đánh giá 300 mẫu báo chí tiếng Việt độc lập. Mục 4.1 trình bày thiết lập đánh giá và cấu trúc định dạng dữ liệu đầu ra; Mục 4.2 báo cáo kết quả nhóm Lexical Overlap (ROUGE); Mục 4.3 báo cáo kết quả nhóm Semantic Quality (BERTScore); Mục 4.4 báo cáo kết quả nhóm Factual Consistency (Tính nhất quán sự thật); Mục 4.5 báo cáo kết quả nhóm Performance (Hiệu năng suy luận); và Mục 4.6 tổng kết chương.

4.1 Thiết lập đánh giá và định dạng dữ liệu

4.1.1 Tập dữ liệu kiểm thử và các mô hình so sánh

Quá trình đánh giá thực nghiệm được vận hành trên tập kiểm thử độc lập gồm 300 mẫu bài báo thu thập từ trang báo điện tử *tienphong.vn*. Ba mô hình được đưa vào đánh giá đối đầu trực tiếp trên cùng 300 mẫu kiểm thử này:

1. **HKL-ViT5 (Phương pháp đề xuất):** Mô hình ViT5-base cải tiến kết hợp cơ chế Selective Long-Context, Keyword Conditioning và Heuristic Factuality Reranking.
2. **Nishikyen/vit5-vietnamese-news:** Mô hình ViT5-base fine-tune chuẩn trên dữ liệu tin tức tiếng Việt (độ dài ngữ cảnh 256/512 tokens).
3. **thnhan/sft_model:** Mô hình ViT5-base tinh chỉnh theo phương pháp SFT.

4.1.2 Cấu trúc định dạng đầu ra dữ liệu

Kết quả sinh ra của mỗi mô hình trên từng văn bản kiểm thử được lưu trữ dưới dạng các tệp văn bản mã hóa UTF-8 với định dạng tiêu chuẩn:

Cấu trúc định dạng tệp kết quả tóm tắt đầu ra (.txt)

```
INDEX:
<index_bài_báo>
GUID:
<mã_định_danh_guid>
TITLE:
<tiêu_đề_bài_báo>
VĂN BẢN GỐC:
<toàn_văn_nội_dung_bài_báo_gốc>
TÓM TẮT DO MODEL SINH:
<nội_dung_bản_tóm_tắt_sinh_ra_bởi_mô_hình>
THỜI GIAN TÓM TẮT:
<thời_gian_xử_lý_tính_bằng_giây>
---Hết---
```

4.2 Kết quả nhóm 1: Lexical Overlap (ROUGE)

Bảng 4.1 báo cáo điểm ROUGE-1, ROUGE-2 và ROUGE-L (tính theo F1 Macro trung bình trên 300 mẫu kiểm thử chung).

Bảng 4.1: Kết quả đánh giá nhóm Lexical Overlap (ROUGE F1 Macro trên 300 mẫu). **In đậm:** Kết quả tốt nhất.

Mô hình	ROUGE-1	ROUGE-2	ROUGE-L
HKL-ViT5 (Ours)	0.5184	0.2932	0.3434
Nishikyen/ vit5-vietnamese-news	0.4707	0.2510	0.3148
thnhan/sft_model	0.4321	0.2227	0.2773

Phân tích kết quả: Mô hình HKL-ViT5 dẫn đầu vượt trội trên cả 3 chỉ số ROUGE. Cụ thể, HKL-ViT5 đạt ROUGE-1 0.5184 (cao hơn Nishikyen +4.77% và cao hơn thnhan +8.63%). Điểm ROUGE-2 đạt 0.2932 (tăng +4.22%) và ROUGE-L đạt 0.3434 (tăng +2.86%). Kết quả này minh chứng rằng việc nén ngữ cảnh toàn văn bằng MMR và Keyword Conditioning giúp mô hình khôi phục được nhiều n-gram quan trọng từ bài gốc mà các mô hình bị cắt ngắn đầu vào bỏ sót.

4.3 Kết quả nhóm 2: Semantic Quality (BERTScore)

Bảng 4.2 báo cáo các chỉ số tương đồng ngữ nghĩa BERTScore (sử dụng mô hình mã hóa ngữ cảnh xlm-roberta-base).

Bảng 4.2: Kết quả đánh giá nhóm Semantic Quality (BERTScore với xlm-roberta-base). **In đậm:** Kết quả tốt nhất.

Mô hình	BERTScore Precision	BERTScore Recall	BERTScore F1
HKL-ViT5 (Ours)	0.8996	0.9020	0.9008
Nishikyen/ vit5-vietnamese-news	0.8972	0.8896	0.8934
thnhan/sft_model	0.8960	0.8790	0.8874

Phân tích kết quả: Ở độ đo ngữ nghĩa BERTScore, HKL-ViT5 đạt F1 0.9008, thiết lập mức hiệu năng cao nhất trong 3 mô hình. Đặc biệt, chỉ số BERTScore Recall đạt 0.9020 (so với 0.8896 của Nishikyen và 0.8790 của thnhan), khẳng định rằng bản tóm tắt do HKL-ViT5 sinh ra bao hàm ngữ nghĩa toàn diện hơn đối với bài viết gốc.

4.4 Kết quả nhóm 3: Factual Consistency (Tính nhất quán sự thật)

Bảng 4.3 báo cáo các chỉ số về tính trung thực thực thể, tính chính xác số liệu, tỷ lệ mâu thuẫn và tỷ lệ ảo giác (sử dụng mô hình NLI MoritzLaurer/mDeBERTa-v3-base-mnli-xnli và trích xuất thực thể underthesea).

Bảng 4.3: Kết quả đánh giá nhóm Factual Consistency. Entity Precision, Number Consistency: càng cao càng tốt; Contradiction Rate, Hallucination Rate: càng thấp càng tốt. **In đậm**: Tốt nhất.

Mô hình	Entity Precision (%)	Number Consistency (%)	Contradiction Rate (%)	Hallucination Rate (%)
HKL-ViT5 (Ours)	81.81%	98.54%	2.11%	39.04%
Nishikyen/vit5-vietnamese-news	79.16%	96.46%	2.90%	45.53%
thnhan/sft_model	76.57%	97.55%	3.99%	48.45%

Bảng 4.4 bổ sung các chỉ số thống kê về xác suất kéo theo logic và số lượng thực thể/con số được xác nhận thực tế.

Bảng 4.4: Thống kê số lượng thực thể, con số và xác suất kéo theo NLI.

Chỉ số	HKL-ViT5	Nishikyen	thnhan
Thực thể được xác nhận / Tổng sinh	706 / 863	581 / 734	513 / 670
Con số được xác nhận / Tổng sinh	472 / 479	409 / 424	438 / 449
Xác suất Entailment trung bình (P_{entail})	0.6063	0.5416	0.5153

Phân tích kết quả: HKL-ViT5 thể hiện ưu thế vượt trội trong việc bảo tồn tính xác thực:

- Entity Precision đạt 81.81% (xác nhận 706/863 thực thể chính xác), vượt trội so với Nishikyen (79.16%) và thnhan (76.57%).
- Number Consistency đạt mức tiệm cận tuyệt đối 98.54% (472/479 con số chính xác), hạn chế tối đa việc nhầm lẫn dữ liệu báo chí.
- Contradiction Rate giảm xuống còn 2.11% (thấp hơn thnhan gần một nửa).
- Hallucination Rate giảm đáng kể xuống 39.04% (so với 45.53% của Nishikyen và 48.45% của thnhan), chứng minh hiệu quả kéo giảm ảo giác của bộ Heuristic Factuality Reranker.

4.5 Kết quả nhóm 4: Performance (Hiệu năng suy luận)

Bảng 4.5 báo cáo các chỉ số thống kê về thời gian suy luận trung bình (tính bằng giây trên mỗi bài báo).

Bảng 4.5: Kết quả thống kê thời gian suy luận (Inference Time). **In đậm:** Tốc độ nhanh nhất.

Mô hình	Mean (s)	Median (s)	P95 (s)	Std (s)
HKL-ViT5	8.0535	5.7128	18.5620	4.7382
(Ours)				
Nishikyen/ vit5-vietnamese-news	3.5313	3.5053	4.5211	0.5923
thnhan/sft_model	6.1358	5.9035	8.1466	1.3003

Phân tích kết quả: Mô hình Nishikyen có thời gian suy luận nhanh nhất (trung bình 3.53 giây/bài) do chỉ chạy suy luận Beam Search đơn trên chuỗi ngắn (256/512 tokens). Trong khi đó, HKL-ViT5 mất trung bình 8.05 giây/bài (trung vị 5.71 giây). Sự gia tăng thời gian này là hợp lý vì HKL-ViT5 phải thực hiện quy trình nén ngữ cảnh 1024 tokens qua MMR và sinh $N = 5$ ứng viên tóm tắt để qua bộ Reranker.

4.6 Tổng kết chương

Thực nghiệm trên 300 mẫu kiểm thử độc lập đã chứng minh tính hiệu quả toàn diện của HKL-ViT5: chiến thắng tuyệt đối trên cả 3 chỉ số ROUGE, đạt BERTScore F1 cao nhất (0.9008), đạt độ chính xác con số 98.54% và kéo giảm tỷ lệ ảo giác xuống 39.04%. Sự gia tăng thời gian suy luận (8.05s) là sự đánh đổi hoàn toàn hợp lý để đổi lấy chất lượng và tính xác thực dữ kiện báo chí.

Chương 5

Phân tích kết quả thực nghiệm

Chương này đi sâu diễn giải và phân tích bản chất đằng sau các kết quả thu được từ 300 mẫu thực nghiệm báo chí. Mục 5.1 phân tích nguyên nhân hiệu năng vượt trội của HKL-ViT5; Mục 5.2 thực hiện phân tích các dạng lỗi phổ biến; Mục 5.3 thảo luận về sự đánh đổi giữa tốc độ và chất lượng; Mục 5.4 phân tích các hạn chế của đề tài; và Mục 5.5 tổng kết chương.

5.1 Phân tích ý nghĩa kết quả

Hiệu năng ấn tượng của HKL-ViT5 (ROUGE-1 đạt 0.5184, BERTScore F1 đạt 0.9008) đến từ sự phối hợp nhịp nhàng giữa ba cải tiến kiến trúc chính:

- **Đóng góp của cơ chế Selective Long-Context:** Việc mở rộng input lên 1024 tokens thông qua thuật toán lọc nén MMR giúp mô hình bao quát thông tin từ cả 3 phần: Mở bài, Thân bài và Kết bài. Trong khi các mô hình baseline như *Nishikyen* (ROUGE-1 0.4707) hay *thnhan* (ROUGE-1 0.4321) chỉ đọc được 256/512 token đầu tiên (bị dính thiên kiến lead bias), HKL-ViT5 không bỏ lỡ các số liệu tổng kết hoặc thông điệp chính nằm ở cuối bài báo dài.
- **Đóng góp của Keyword Conditioning:** Việc đưa danh sách từ khóa vào trước ngữ cảnh giúp định hướng cơ chế chú ý của Decoder ViT5. Mô hình giảm bớt việc lan man sang các chi tiết phụ và tập trung sinh ra bản tóm tắt xoay quanh các thực thể và chủ đề cốt lõi.
- **Đóng góp của Heuristic Factuality Reranker:** Việc sinh ra $N = 5$ ứng viên và lọc lại bằng điểm số nhất quán thực thể (81.81%) và con số (98.54%) đã tạo ra một chốt chặn hiệu quả. Cơ chế này giúp kéo giảm đáng kể tỷ lệ ảo giác (xuống 39.04% so với 45.53% ở *Nishikyen* và 48.45% ở *thnhan*) và giảm tỷ lệ mâu thuẫn xuống 2.11%.

5.2 Phân tích lỗi

Mặc dù đạt kết quả tích cực, qua quá trình kiểm thử chi tiết trên 300 mẫu, nghiên cứu nhận diện 3 dạng lỗi phổ biến mà HKL-ViT5 có thể gặp phải:

1. **Lỗi trích chọn Chunk chứa từ khóa nhiều:** Trong một số bài báo có phong cách viết hoa mỹ hoặc chứa nhiều từ cảm thán, thuật toán MMR có thể chọn nhầm các chunk chứa từ khóa xuất hiện nhiều lần nhưng không mang hàm lượng thông tin cao, dẫn đến bản tóm tắt bị thiếu ý chính.
2. **Lỗi tách từ và tên riêng phức tạp:** Một số danh từ riêng tiếng Việt kéo dài hoặc tên tổ chức nước ngoài được phiên âm không chuẩn có thể bị bộ phân đoạn câu/từ chia gãy, khiến 18.19% thực thể chưa được xác nhận hoàn toàn.
3. **Lỗi ranh giới con số:** Mặc dù Number consistency đạt 98.54%, trong một số ít bài báo tài chính chứa quá nhiều chuỗi số liệu (ví dụ: so sánh doanh thu các quý), mô hình đôi khi ghép nhầm con số của chỉ số này cho chỉ số khác nếu hai con số đứng quá gần nhau trong cùng một chunk.

5.3 Phân tích sự đánh đổi hiệu năng

Quá trình tích hợp các bước xử lý tiền suy luận và hậu suy luận (Factuality Reranking trên $N = 5$ ứng viên) khiến thời gian suy luận trung bình của HKL-ViT5 đạt 8.0535 giây/bài (trung vị 5.7128s), cao hơn so với Nishikyen (3.5313s) và thnhan (6.1358s).

Tuy nhiên, sự gia tăng thời gian suy luận này là hoàn toàn xứng đáng so với lợi ích thu được: bản tóm tắt đạt độ chính xác dữ kiện cao hơn vượt trội (+4.77% ROUGE-1, 98.54% con số chính xác) và bảo toàn được ngữ cảnh toàn văn. Đối với bài toán tóm tắt tin tức báo chí, độ tin cậy thông tin luôn được ưu tiên hàng đầu so với tốc độ xử lý miligiây.

5.4 Hạn chế của nghiên cứu

Nghiên cứu còn tồn tại hai hạn chế chính:

- **Giới hạn miền dữ liệu:** Bộ dữ liệu thực nghiệm hiện mới được thu thập từ domain tin tức báo chí *tienphong.vn*. Hiệu năng của HKL-ViT5 trên các miền văn bản đặc thù khác như văn bản pháp luật, báo cáo y khoa hay tài liệu kỹ thuật vẫn cần được kiểm chứng thêm.
- **Kích thước mô hình nền:** Mô hình hiện sử dụng xương sống là VietAI/ViT5-base (220M tham số). Việc mở rộng lên ViT5-large hoặc kết hợp với các mô hình ngôn ngữ lớn tiếng Việt thế hệ mới chưa được triển khai do giới hạn về hạ tầng GPU.

5.5 Tổng kết chương

Chương này đã diễn giải nguyên nhân giúp HKL-ViT5 đạt ROUGE-1 0.5184 và BERTScore F1 0.9008, phân tích 3 dạng lỗi phổ biến, thảo luận bài toán đánh đổi giữa tốc độ (8.05s) và chất lượng, đồng thời thừa nhận các hạn chế về miền dữ liệu và kích thước mô hình. Chương 6 sẽ tổng kết toàn bộ đề tài và nêu hướng phát triển.

Chương 6

Kết luận và hướng phát triển

6.1 Tóm tắt các kết quả và đóng góp chính

Báo cáo bài tập lớn này đã nghiên cứu, cải tiến và đánh giá thành công mô hình HLK-ViT5 cho bài toán tóm tắt văn bản tiếng Việt ngữ cảnh dài từ dữ liệu báo chí điện tử. Đề tài mang lại ba đóng góp chính:

1. **Giải quyết rào cản ngữ cảnh dài:** Thiết kế và cài đặt thành công pipeline 13 bước kết hợp chia đoạn bảo toàn câu, khoảng 1 câu, chấm điểm nổi bật và lọc không trùng lặp bằng MMR. Kỹ thuật này giúp mở rộng cửa sổ ngữ cảnh đầu vào ViT5 lên 1024 tokens mà vẫn đảm bảo tính cô đọng thông tin.
2. **Kiểm soát tính xác thực và ảo giác:** Tích hợp cơ chế điều kiện hóa từ khóa và xây dựng bộ xếp hạng lại ứng viên tóm tắt dựa trên độ chính xác thực thể và tính nhất quán con số, kéo giảm đáng kể hiện tượng ảo giác trong sinh văn bản tiếng Việt.
3. **Đánh giá hệ thống trên Corpus nội địa:** Thực nghiệm toàn diện trên bộ dữ liệu 15.620 mẫu từ *tienphong.vn*, đối chiếu HLK-ViT5 với hai baseline Nishikyen và **tnhan** trên bộ đo lường 4 nhóm: Lexical Overlap, Semantic Quality, Factual Consistency và Inference Time.

6.2 Hướng phát triển tương lai

Từ các kết quả và hạn chế đã chỉ ra ở Chương 5, nghiên cứu đề xuất ba hướng phát triển tiếp theo:

- **Mở rộng sang kiến trúc ViT5-large và LLM tiếng Việt:** Đưa pipeline Selective Long-Context và Reranking áp dụng cho mô hình ViT5-large hoặc các LLM tiếng Việt tiên tiến như PhoGPT, Vistral để nâng cao hơn nữa khả năng diễn giải ngữ nghĩa.
- **Tối ưu hóa tốc độ suy luận:** Tối ưu thuật toán MMR và song song hóa bước Reranker bằng kỹ thuật Batch Inference hoặc ONNX Runtime, hướng tới việc triển khai mô hình dưới dạng RESTful API hoặc Tiện ích mở rộng trình duyệt hoạt động thời gian thực.
- **Mở rộng miền dữ liệu đánh giá:** Thu thập và kiểm thử HLK-ViT5 trên các miền văn bản chuyên biệt như văn bản luật, báo cáo tài chính và hồ sơ y tế tiếng Việt để đánh giá khả năng tổng quát hóa của phương pháp đề xuất.

TÀI LIỆU THAM KHẢO

- [1] C. Nguyen và cs. “ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation”. Trong: *arXiv preprint arXiv:2205.06457* (2022).
- [2] D. Q. Nguyen và cs. “PhoBERT: Pre-trained language models for Vietnamese”. Trong: *Findings of EMNLP 2020*. 2020, tr. 1037–1042.
- [3] A. Vaswani và cs. “Attention Is All You Need”. Trong: *Advances in Neural Information Processing Systems (NeurIPS)* 30 (2017), tr. 5998–6008.

PHỤ LỤC

Phụ lục A: Ví dụ định dạng tệp kết quả tóm tắt đầu ra

Dưới đây là một ví dụ minh họa về tệp kết quả tóm tắt dạng .txt được sinh ra từ mô hình HLK-ViT5 trên tập dữ liệu kiểm thử báo chí tiếng Việt:

Ví dụ định dạng đầu ra của tệp kết quả (.txt)

```
INDEX:
1042
GUID:
tp-2026-0810-0042
TITLE:
Bộ Giáo dục và Đào tạo công bố phương án thi tốt nghiệp THPT
VĂN BẢN GỐC:
Bộ Giáo dục và Đào tạo chính thức công bố phương án tổ chức kỳ thi
tốt nghiệp THPT áp dụng từ năm 2025 trở đi. Theo đó, học sinh sẽ thi
4 môn bao gồm 2 môn bắt buộc là Toán, Ngữ văn và 2 môn lựa chọn trong
số các môn còn lại. Phương án này nhằm giảm áp lực thi cử cho học sinh...
TÓM TẮT DO MODEL SINH:
Bộ GD&ĐT công bố phương án thi tốt nghiệp THPT từ năm 2025 với 4 môn thi
gồm Toán, Ngữ văn bắt buộc và 2 môn tự chọn, giúp giảm áp lực thi cử.
THỜI GIAN TÓM TẮT:
1.42
---Hết---
```

Phụ lục B: Cấu hình môi trường thực nghiệm

Bảng 6.1 tóm tắt cấu hình chi tiết phần cứng và phần mềm được sử dụng để huấn luyện và đánh giá mô hình HLK-ViT5.

Thành phần	Thông số / Phiên bản
Hệ điều hành	Ubuntu 22.04 LTS
Card đồ họa (GPU)	NVIDIA RTX 4090 (24GB VRAM)
Bộ nhớ RAM	64GB DDR5
Ngôn ngữ lập trình	Python 3.10
Thư viện Deep Learning	PyTorch 2.1.2, CUDA 12.1
Thư viện NLP	Hugging Face Transformers 4.36.0, Datasets 2.15.0
Mô hình nền	VietAI/vit5-base

Bảng 6.1: Cấu hình chi tiết môi trường thực nghiệm HLK-ViT5